分类号 TP181　　密 级

U D C 336.7　　编 号

中南財經政法大學

硕 士 学 位 论 文

机器学习方法在阿尔兹海默症诊断中的应用

研究生姓名：孙 晓 驰

校内导师姓名、职称：吴 远 山 教 授

校外导师姓名：钟 浙 晓

学科门类：应用统计专业学位

专业名称：应 用 统 计

研究方向：大数据分析方向

入学时间：二〇一九年九月

二〇二一年五月二十四日

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

Application of Machine Learning Methods in the Diagnosis of Alzheimer's Disease

Sun Xiaochi

2021.05.24

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

中南财经政法大学学位论文独创性声明和使用授权声明

学位论文独创性声明

本人所呈交的学位论文，是在导师的指导下，独立进行研究所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写的作品。对本文的研究做出重要贡献的个人和集体，均已在文中标明。

本声明的法律后果由本人承担。

论文作者（签名）：孙晓驰

2021 年 5 月 24 日

学位论文使用授权书

本论文作者完全了解学校关于保存、使用学位论文的管理办法及规定，即学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权中南财经政法大学将本学位论文的全部或部分内容编入有关数据库，也可以采用影印、缩印或扫描等复制手段保存或汇编本学位论文。

注：保密学位论文，在解密后适用于本授权书。

论文作者（签名）：孙晓驰

2021 年 5 月 24 日

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

摘要

阿尔兹海默症是一种常出现老年群体中的神经性脑疾病，是全球第四大死亡原因。我国 2019 年的研究显示，中国老年人群痴呆患病率接近 6%，约有 1000-1100 万人正在经受着疾病带来的痛苦，一项 2019 年的研究显示，预计在不久的将来发病总人数会有显著增加。

阿尔兹海默症病症情况较多且复杂，诊断需要大量的检查，检查费用高昂，另外还存在我国人民群众对医疗需求日益加深和医疗资源分配不均之间的矛盾，因此阿尔兹海默症在诊断阶段上会遇到许多困难。根据资料调查显示，我国的阿尔兹海默症患者诊断时超过半数的人都已经是中重度患者，而阿尔兹海默症越早治疗康复起来就越快，因此如何早期诊断出阿尔兹海默症具有重要研究意义。

近几年来，人工智能在医疗领域发挥了重要意义。医学辅助诊断能够通过机器学习方法对医学影像进行识别，这样可以快速发现病症所在，提高医疗效率。因此将阿尔兹海默症诊断诉诸于人工智能，通过机器学习算法实现智慧辅助诊疗，就能够在一定程度上提前诊断出阿尔兹海默症，使得患者在病情早期阶段就能被诊断，大大提高了治愈率。

综上，本文基于以上阿兹海默症受众广、危害大、诊断复杂的背景出发，使用 ADNI 数据库中的生物标志物、人口统计学、认知评估等数据，利用多种机器学习算法实现阿尔兹海默症的病情诊断预测。

以下为本文的研究框架。首先对数据进行哑变量处理、归一化后再进行构建模型。在正式建模之前，首先选择代价权重比值，用以计算使得模型加权错判率最低的分类阈值，从而降低模型的漏诊率。建模总共分为四个部分。第一部分，使用正则化迭代 PCA 插补法、随机森林插补法分队对缺失数据集进行插补，得到两个完整的数据集 Logistic 回归模型。再利用向前选择法，找出对阿尔兹海默症诊断解释力最强的变量。第二部分，利用上述两个插补完成的数据集建立支持向量机模型。第三部分，构建插补法随机森林模型，并给出特征重要性分数。第四部分，利用 SAEM 法，选择使模型收敛速度最快的参数，一次性完成数据的插补和 Logistic 回归模型的建立。最后对模型结果进行比较，并给出对于阿尔兹海默症病情诊断解释性强的变量。为减小偶然性带来的建模结果影响，本文将上述过程重复 10 次，用 10 次建模得到的平均准确率、精确率、灵敏度、特异度、AUC 等指标进行模型间的比较。结果显示，预测能力最好的模型的 AUC 值能够达到 98.05%，准确率和召回率分别可以达到 91.62%和 98.78%。

关键词：阿尔兹海默症；正则化迭代 PCA 插补法；随机森林插补法；SAEM

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

Abstract

Alzheimer's disease is a neurologic brain disease that occurs most often in the elderly population and is the fourth leading cause of death worldwide. China's 2019 research shows that the prevalence rate of dementia among the elderly population in China is about to 6%, and more than 10 million people are suffering from the disease. And according to a 2019 study, the total number of cases is expected to increase significantly in the near future.

The symptoms of Alzheimer's disease are very complex, and the diagnosis requires a large number of examinations, and the examination costs are high. In addition, there is also the contradiction between the deepening medical demand of the Chinese people and the uneven distribution of medical resources. Therefore, Alzheimer's disease will encounter many difficulties in the diagnosis stage. According to the data survey, more than half of the Alzheimer's patients in China are already moderate to severe patients when they are diagnosed, and the earlier the Alzheimer's disease is treated, the faster the recovery will be. Therefore, how to diagnose Alzheimer's disease early has important research significance.

In the past few years, artificial intelligence has played an important role in the medical field. Medical Assisted Diagnostic (MAD) can identify medical images through machine learning methods, which can quickly find the location of the disease and improve medical efficiency. Therefore, by resorting to artificial intelligence in the diagnosis of Alzheimer's disease and realizing intelligent assisted diagnosis and treatment through machine learning algorithm, Alzheimer's disease can be diagnosed in advance to a certain extent, so that patients can be diagnosed at the early stage of Alzheimer's disease and the cure rate can be greatly improved.

To sum up, based on the background of the wide audience, great harm and complex diagnosis of Alzheimer's disease mentioned above, this paper uses biomarkers, demographics, cognitive assessment and other data in the ADNI database, and uses a variety of machine learning algorithms to realize the diagnosis of Alzheimer's disease.

The following is the research framework of this paper. Firstly, the classification variables in the data are treated with dummy variables and normalized, and then the model is constructed. Before the formal modeling, the cost weight ratio was firstly selected to calculate the classification threshold value which made the model weighted misjudgment rate the lowest, so as to reduce the misdiagnosis rate of the model. The modeling is divided into four parts. In the first part, the regularized iterative PCA interpolation method and

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

random forest interpolation method were used to interpolate the missing data sets, and two complete Logistic regression models of data sets were obtained. The forward selection method was used to identify the most powerful variables for the diagnosis of Alzheimer's disease. In the second part, the support vector machine model is established by using the data set completed by the above two interpolation. In the third part, the interpolation random forest model is constructed and the feature importance score is given. In the fourth part, the SAEM method is used to select the parameters that make the model converge fastest, and the data interpolation and Logistic regression model are completed at one time. Finally, the model results are compared and the variables that are highly explanatory for the diagnosis of Alzheimer's disease are given.

In order to reduce the impact of contingency, the above process was repeated 10 times in this paper. Then calculate the average value of accuracy, accuracy, sensitivity, specificity, AUC and other indexes obtained from 10 modeling results. The results show that the AUC value of the model with the best predictive ability can reach 98.05%, the accuracy and recall can reach 91.62% and 98.78%, respectively.

Key Words: Alzheimer's disease; regularization iteration PCA imputation; random forest imputation; SAEM

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

目录

绪论 1
一、选题背景与研究意义 1
二、国内外研究综述 2
三、研究思路与方法 4
第一章　相关研究方法介绍 5
第一节　多重插补法概述 5
一、基于主成分的多重插补法 6
二、基于随机森林的多重插补法 8
三、SAEM 法 10
第二节　机器学习方法概述 11
一、随机森林 11
二、Logistic 回归 14
三、支持向量机 16
第二章　数据介绍与描述性统计 21
第一节　数据来源与描述性统计 21
一、数据来源 21
二、数据描述性统计 21
第二节　数据预处理 25
一、哑变量处理 25
二、归一化 25
第三节　模型评价指标 25
一、准确率、精确率、召回率、特异度 25
二、ROC 曲线与 AUC 值 27
三、加权误判率 27
第三章　阿尔兹海默症诊断实证研究 29

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

第一节　建模过程与结果 29
一、代价权重比值的确定 29
二、插补法 Logistic 回归的建模过程与结果 32
三、插补法 SVM 的建模过程与结果 34
四、插补法随机森林的建模过程与结果 37
五、SAEM 法的建模过程与结果 41
第二节　模型结果对比与分析 42
一、预测精度对比 42
二、重要解释变量 46
研究总结与展望 50
一、研究总结 50
二、研究展望 50
参考文献 52
附录 57

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

绪论

一、选题背景与研究意义

阿尔兹海默症[1]（Alzheimer's disease）是一种常出现于老年群体中的神经性脑疾病，是全球第四大死亡原因。其通常以记忆渐进性丧失和认知功能退化为特征，患者逐渐从正常老年人转变为轻度认知障碍，随着患病时间神经元及其连接被逐渐破坏，导致认知功能丧失，最终成为老年痴呆。我国 2019 年的报告显示，我国中老年群体中大约有 6%的人患有老年痴呆，1000 万人以上正在经受着疾病带来的痛苦。一项 2019 年的研究显示，随着中国社会的老龄化，预计在不久的将来发病总人数会有显著增加[2]。

阿尔兹海默症病症情况较多且复杂，诊断需要大量的检查，而具备全套早期诊断的医院寥寥无几，加上病理检查费用高昂等多重原因，使得阿尔兹海默症诊断技术和手段上亦面临难题。此外我国老年人群体所占社会比例日益增加，加之人民群众“看病难”这一问题还未完全解决，我国现有的医疗卫生资源配置不合理，偏远贫困地区享有的医疗资源相比于一线城市少之又少。正因如此，我国的阿尔兹海默症患者在诊断时超过半数的人都已经是中重度患者。而阿尔兹海默症越早治疗治愈的可能性就越高，因此如何早期诊断出阿尔兹海默症具有重要研究意义。

近年来，人工智能在医疗领域大放异彩，应用场景极为广泛。如在诊前诊中诊后提供导诊、病例录入、复查提醒的 AI 虚拟助理。以及基于深度学习算法的医学辅助诊断能够通过图像识别技术对医学影像进行识别，标注病灶关键信息，能够帮助医生快速发现病灶，提高影像诊断效率。此外还可以收集大量医疗影像数据和临床诊断信息，不断对 AI 系统进行优化训练，促使其提高诊断能力，降低复杂疾病的误诊率。人工智能在医疗领域的应用和发展，很大程度上缓解了之前医疗工作中的繁琐问题。因此将阿尔兹海默症诊断诉诸于人工智能，通过机器学习算法实现智慧辅助诊疗，就能够在一定程度上大大提高医疗效率。

综上，本文将基于以上阿尔兹海默症受众广、危害大、诊断复杂的背景出发，通过收集 ADNI 数据库中的生物标志物等数据，利用多种机器学习算法实现阿尔兹海默症的病情诊断预测。本文为寻找对于病情诊断最为准确的一套方法做出了一些技术尝试，整套流程具备可重复性高的优势，增加了诊断阿尔兹海默症的效率，能重新合理部署分配医疗资源。这一研究结果对医疗手段具有指导意义，模型能够筛选得到与阿

[1] 又名老年痴呆症。

[2] 王英全,梁景宏,贾瑞霞,等.2020-2050 年中国阿尔茨海默病患病情况预测研究[J].阿尔茨海默病及相关病,2019,2(01):289-298.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

尔兹海默症的诊断和预后高度关联的重要性变量，使得老年群体患者能够更快捷简单地寻求医疗帮助，病情能够更早的被诊断，能够提高人群健康水平、降低患者经济负担，对于治疗阿尔兹海默症具有重大现实意义。

二、国内外研究综述

许多学者对影响阿尔兹海默症患者的疾病特征进行了探索研究。Priyanka Bhatt 等人发现脑脊液中 tTau 和 pTau 蛋白是最有前景和最富有信息的阿尔兹海默症生物特征[3]。Jack C de la Torre 表明血管危险因子在老年期认知衰退和阿尔兹海默症的发生中起着关键作用。唐牟尼、刘协和等人通过研究发现单身或离异的女性，以及生育子女数较少的女性患阿尔兹海默症的风险更高。宋祯彦、余婧萍等人通过研究发现与神经炎症有关的基因和信号通路的失调可能是老年痴呆的危险因素，为寻找防治痴呆的潜在生物标志物提供了出发点。

大量与阿尔兹海默症病情进展相关的标志物的发现和研究，以及随着众多性能优良的机器学习算法的涌起，使得利用机器学习实现阿兹海默症的诊断成为了可能。不少研究者采用生物标志物和神经影像图片来进行阿尔兹海默症病情诊断，并获得了较好的效果。

国外学者 Michael Farnum 等采用 ADNI 数据库中可用的各种类型的基线数据，包括核磁共振、人口统计、遗传和认知测试等，使用了能够进行稳定的特征选择的稀疏 Logistic 回归对 319 个样本进行建模，并给出了潜在预测因素，实现了 MCI 患者是否会发生 MCI 到 AD 的转变预测，最终 AUC 达到了 0.8587。Ahsan Bin Tufail，Ali Abidi 等提出了一种基于渐进二类近端支持向量机决策（pTCDC-PSVM）分类器的新方法来区分正常对照、轻度认知障碍和痴呆患者。文章使用了 362 个来自 OASIS 数据库中的样本的结构磁共振成像（sMRI）相位图像数据，利用独立分量分析技术提取 sMRI 中有用的特征，并将其输入到 pTCDC-PSVM 中进行分类。A.V. Lebedeva，E. Westmanb 等利用 ADNI 数据库中 575 个样本的不同结构的 MRI 图像训练模随机森林模型。结果表明，与线性 SVM 模型相比随机森林模型显然更好，最好的模型对于痴呆类别的召回率能够达到 88.6%。且将其模型应用于全新的 AddNeuroMed 数据库中的受试者时，最好的模型产生了相同的性能且没有实质的准确性下降，表明了模型具有良好的稳健性。Silvia Basaia, Federica Agosta 等提出了一种基于深度学习的卷积神经网络方法，利 ADNI 数据库中的 MRI 单个横断面图像对不同病情阶段两两进行预测，最好的一次预测的召回率达到了 98%以上。

国内也有一些学者开展了利用机器学习方法对阿尔兹海默症进行诊断的研究。潘祖江、刘宁等提出了一个进展模型，该模型将疾病诊断流程分成主任务和辅任务，并

[3] C Davatzikoss, P Bhatt, LM Shaw, et al. Prediction of MCI to AD conversion, via MRI, CSF biomarkers, and pattern classification[J]. Neurobiol Aging, 2010, 32(12): e19-e27.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

利用 ADNI 数据库中的多种临床特征，其准确率能够达到 90.98%[4]。文章中将这一方法与其他基准模型进行对比，验证了其准确率的优越性。Bibo Shi, Yani Chen 等开发了一种新的非线性度量学习方法来提高对痴呆及其早期轻度认知障碍（EMCI）的生物标志物识别。在约束优化框架下，该方法学习一种平滑的非线性特征空间变换，使同一类的样本相互靠拢，而不同类的样本则被推得更远而能更好的完成分类。选择薄板样条（TPS）作为几何模型，因为它在处理复杂变形时具有显著的通用性和表示能力。姚丽丽和范炤利用 543 个研究对象的 sMRI 图像（sMRI）和人口统计学共 276 项指标数据进行研究，分别使用 LI-Logistic 回归模型、和 L1-支持向量机模型来进行特征筛选和模型训练，构建正常人和阿尔兹海默症病情阶段的二分类器，其准确率在 90%以上。仝政霖从基因表达的角度展开研究，利用堆叠去噪自编码器实现阿兹海默症分类和是否会发展成为轻度认知障碍的转化预测，该模型能够达到 85.77%的准确率。林颖使用脑部 MRI 图像进行研究，使用其提出的一种结合 2D 卷积神经网络与长短时记忆网络的算法，训练深度卷积生成对抗网络生成 MRI 图像，堆叠一个两层的长短时记忆网络模型，然后结合输入的特征序列与 LSTM 层的隐藏状态进行分类，分类结果 AUC 能够达到 0.9。

综合以上国内外对于机器学习算法在阿尔兹海默症诊断上的研究现状总结如下。

第一，在研究目标上，主要可以分为阿尔兹海默症的诊断和病变预测。前者是通过各种机器学习方法来对正常人和阿尔兹海默症病人进行判别。后者则是对一个人将来是否会发生病情的恶化进行判别，其中病情恶化指正常人转变为轻度认知障碍或痴呆，以及轻度认知障碍转变为痴呆。前者的研究重点在于当下的诊断，以及探索识别病情阶段的最为重要的标志物和水平。后者的研究重点在于预后，以及探索影响病情恶化的危险因素和保护因素。目前，国内对于阿尔兹海默症的研究主要在因素探索上，相比与国外对于使用机器学习方法进行阿尔兹海默症诊断和病变预测的研究尚不充分。

第二，在研究方法上，使用 SVM、随机森林、KNN、神经网络、深度学习方法进行阿尔兹海默症诊断的研究较多，而利用 Logistic 回归进行对模型的性能分析的文章较少。这可能是由于 Logistic 回归模型在预测精度上通常不如 SVM、随机森林等方法。然而这些方法的解释性较差，并不利于我们研究各种生物标志物以及患者行为习惯等因素对病情的影响程度。然而 Logistic 回归的解释性相比其他模型更强、也更具备稳定性。因此通过寻求其他方法来提升 Logistic 回归模型的准确度再应用于阿尔兹海默症诊断是可以进行的尝试。

第三，在解释变量上，大量的研究使用的是神经影像学 MRI 和 PET 以及 CSF 测量。然而除了 MRI 和 CSF 测量，ADNI 数据库中还有各种临床数据和认知评估分数，

[4] 潘祖江,刘宁,张伟,等.基于层次注意力机制的多任务疾病进展模型[J].计算机科学,2020,47(09):185-189

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

包括迷你精神状态检查、临床痴呆评定，阿尔茨海默症评估，逻辑记忆评分和日常生活能力评分等。这些都是对于判别阿尔兹海默症可能有用的数据集。临床数据和认知评估比影像学或许比 CSF 生物标志物更具有潜在优势。一方面，认知数据的可获得性高于 MRI、PET 和 CSF 测量。因为认知测试检测便捷，只需要通过问卷和游戏的形式获得。时间成本和经济成本都要低于 MRI、PET 和 CSF 测验。另一方面，不论是在 ADNI 数据库还是在真实的临床检验中，并非所有的患者都进行了 MRI 和 PET 扫描，因此使用影像学和 CSF 生物标志物可能严重限制参与筛选研究的人数。

国内外学者对于使用机器学习方法实现阿尔兹海默症病情诊断的研究工作已经做出了很多方法探索和方法创新，然而大部分研究的准确率和对于患病人群的召回率仍然不够理想，难以应用到临床当中且难以真正实现医学辅助诊断的功能。本人通过梳理发现可以从以下三点出发来优化预测性能。

第一，当前研究所使用的样本量都较小，主要有以下原因。部分文章是使用受试者的 MRI 或者 sMRI 图像进行建模的。尽管 ADNI 数据库中虽然已有 2000 以上的受试者参与，然而当前正在进行的 ADNI3 期研究中的数据很多并没有及时更新，并且之前期数的研究中也仅有一半多的人接受了 MRI 检查。因此仅选择图片数据来进行预测，就会丢失那些没有 MRI 图像数据的样本。

第二，绝大部分文章在使用数据进行预测时，在处理缺失的时候仅仅是通过均值填充的方法得到完整数据集，这样的处理缺失值的方式比较粗暴，没有利用其他变量的信息，进而影响预测的准确性。由于 ADNI 数据库中的数据大量变量都存在着缺失，因此选择性能优良的插补方法妥善对缺失数据进行插补，能够对模型的预测性能带来优化。

第三，由于我们所构建的模型是用于病情诊断，因此对于患病者识别为正常人的错判风险是远高于将正常人错判为患者的。而绝大部分文章没有考虑到这一点，因此需要通过一些方法来降低患病者被诊断为正常人的误判率。

本文将通过以下方法来克服上述三点。针对第一点，可以选择 ADNI 数据库已有的生物标志物进行预测，其中不仅包括了各实验室已经处理好的 MRI 图像提供的脑部各子区域的指标情况，还有很多其他的认知能力、人口统计学等变量。针对第二点，本文将利用一种基于 MH 抽样，对不完整的数据我们可以进行应用 Logistic 回归插补法来解决数据缺失问题，以及同样性能优良的正则化迭代 PCA 插补法、随机森林插补法来完成对数据的插补和建模工作。针对第三点，本文将利用加权误判率这一指标，以不同权重来衡量不同的错误的代价，并将数值作为分类结果的相关联，每次选择使得加权误判率最小的阈值进行分类预测，以达到提升患病类别召回率的效果。

三、研究思路与方法

本文将使用 ADNI 数据库中的阿尔兹海默症数据进行分析，具体研究思路与方法

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

如下：

1、首先对 ADNI 数据库下载得到的 700 余个数据及数据说明文件进行梳理，整理 ADNI 数据库中的所有生物标志物、检验结果、脑成像信息、人口统计学数据，根据变量和病人的数据缺失情况进行变量和样本的删减最终得到要分析的子数据集。

2、探索部分变量在健康老年人、轻度认知障碍、痴呆这三类人群中的分布情况，通过描述性统计初步了解与阿尔兹海默症病情进程相关的变量及水平。

3、将数据进行预处理，对整理好的原始数据进行清洗，去除其中存在的异常。再对清洗后的数据进行归一化、哑变量处理，整理出缺失比例信息。

4、在建模之前，首先通过研究模型和准确率等指标的关系来选择合适的代价权重比值，以此来计算加权误判率，从而影响分类结果的阈值，降低漏诊率。建模总共分三个部分。第一部分，对缺失数据进行插补，通过随机森林插补法、正则化迭代 PCA 插补法得到完整的数据集，再分别建立 Logistic 回归模型。然后利用向前选择法，找出对阿尔兹海默症诊断解释力最强的变量。第二部分，利用上述插补法得到的两个完整的数据集分别建立 SVM 模型。第三部分，同样利用两个插补得到的数据集建立插补法随机森林模型，并计算变量重要性分数。第四部分，利用 SAEM 法直接对缺失数据进行建模，选择使模型收敛速度最快的参数，一次性完成数据的插补和模型的建立。

5、将上述六种模型结果进行对比分析。为减小偶然性带来的建模结果影响，本文将对建模过程重复进行 10 次，用 10 次建模得到的平均准确率、精确率、灵敏度、特异度、AUC 等指标进行模型间的比较。最终选出最适宜阿尔兹海默症病情诊断的机器学习方法。

6、通过建模结果给出对于阿尔兹海默症病情诊断的变量，以及其影响程度排序，并给出相关结论。

第一章　相关研究方法介绍

第一节　多重插补法概述

不论是在医学研究还是其他领域中，缺失数据是普遍存在的。它可能发生的原因有很多，包括无回答、检测设备精度存在限制、数据丢失以及其他不可抗力因素。由于常规的统计方法均建立在完整数据的基础上，因此在统计研究中，缺失值的填补是实证研究中首先要解决的问题。

当变量缺失比例较低时，如果样本量充足可以通过删除含有缺失的个体，或者通

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

过成列删除的方式处理。这种方式的优点在于处理起来简单快捷，不需要特别的运算，但是缺点在于数据量的减少造成了信息损失，尤其是在缺失变量是一个重要的解释变量时。

因此当变量缺失比例较高时，不能直接进行删除，而是应选择插补法对数据进行插值。其主要的原理是通过观测到的数据给出缺失值的插补值。简单的插补可以将变量的均值、中位数或众值补插到缺失值的位置上。这种插补方式最为常见、便捷，然而这会使得总体数据的方差降低，改变样本中变量的分布。

对于插补法的研究一直是统计分析领域的研究热点，从单一插补法发展到多重插补法，统计性能优良的插补法层出不穷。然而大多数可用的插补方法只能应用于某一种变量类型，对于同时包含连续型变量或者分类变量的混合类型数据，通常是把两种类型的变量分开处理的。而本文所要研究的数据，包含了大量的连续型变量和分类变量，为一次性得到插补值，将使用以下几种能够同时处理不同类型变量的多重插补法方法。

一、基于主成分的多重插补法

（一）迭代 PCA 插补法

主成分分析法[5]是利用降维的思想，从空间的角度出发，将 n 维特征映射到 m 维上，通过不同维度转换的方式就可以让个体在子空间中尽可能的分离。正交变换是一种简单、直接的解决相关问题的方法，使用这种方法转换得到的变量，具有不相关性，学者们称之为主成分。

设$X_{n\times p}$是一个由n个个体和p个变量组成的矩阵，PCA 法可以归结为找到一个秩为s的矩阵$\hat{X}$，使其在最小二乘意义上是$X_{n\times p}$的最佳近似：

$$\left\|X_{n\times p}-\hat{X}_{n\times p}\right\|^2 \tag{1-1}$$

对矩阵X进行奇异值分解，分解后的矩阵可以表示为$\hat{X}=U_{n\times s}\Lambda_{s\times s}^{\frac{1}{2}}V_{p\times s}^{T}$。矩阵$U\Lambda^{\frac{1}{2}}$即为得分矩阵或主成分矩阵。$\hat{X}$同时也是（1-1）式的极大似然估计，矩阵$\hat{X}$中的元素可以表示为：

$$\hat{x}_{ij}=\sum_{s=1}^{S}\sqrt{\lambda_s}u_{is}v_{js} \tag{1-2}$$

对于一个完整的数据集，PCA 将通过（1-2）式得到估计结果。对于一个缺失的数据集，PCA 将忽略缺失值，根据所有没有缺失的个体通过最小化（1-1）式所示的

[5] Principal component analysis, PCA

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

最小二乘准则来求解。可以在这个准则中引入一个权重矩阵 W，当x_{ij}缺失时有$w_{ij}=0$，反之$w_{ij}=1$，如（1-3）所示：

$$\left\|W_{n\times p}*\left(X_{n\times p}-U_{n\times s}\Lambda_{s\times s}^{\frac{1}{2}}V_{p\times s}^{T}\right)\right\|^{2} \tag{1-3}$$

这样做的目的是忽略缺失的元素来估计 PCA 的参数。易知（1-3）和（1-1）式中的准则是等价的。与完整数据集不同在于，（1-3）式不能通过显式的方法最小化准则求解，所以需要通过迭代算法来实现，如 EM 算法。迭代 PCA 算法[6]具体分为以下几个步骤。

步骤一：首先忽略缺失数据计算各变量的均值作为初始值来填补缺失元素。

步骤二：预先给定一个维度值s，将（1-2）式应用到 a 步得到的完整数据集上，就可以预测出缺失值。

步骤三：将预测值填补到缺失处，用新的矩阵继续重复 b 中过程，直到矩阵的总变化低于经验确定的阈值。

（二）正则化迭代 PCA 插补法

当变量之间有很强的相关性或者缺失数据很少的时候，基于 EM 算法的迭代 PCA 算法可以对缺失值给出良好的估计。然而这一算法在数据存在大量缺失或者数据有噪声时很容易产生过拟合。这意味着观测数据拟合情况良好，但是对测试集预测时表现得很差。为了解决这个问题，可以采用以下正则化迭代 PCA 插补法[7]，具体步骤如下。

步骤一：用初始值（比如均值）填补缺失值，得到初始插补矩阵X^0。然后计算X^0的每一个变量的均值，得到一个均值向量。每行重复该均值向量，可以得到一个矩阵记作M^0。

步骤二：在插补的数据集上应用 PCA。设迭代次数为k，$k=1,2,\dots,K$。在第k次迭代中，对$(X^{k-1}-M^{k-1})$进行奇异值分解。

步骤三：构建如下拟合矩阵：

$$\hat{x}_{ij}^{k}=\sum_{s=1}^{S}\left(\frac{\sqrt{\lambda_s^k}-(\hat{\sigma}^2)^k}{\sqrt{\lambda_s^k}}\right)u_{is}^{k}v_{js}^{k} \tag{1-4}$$

其中，误差项方差的估计为：

$$(\hat{\sigma}^2)^k=\frac{\left\|X^{k-1}-U^k(\Lambda^k)^{1/2}(V^k)^T\right\|^2}{np-nS-pS+S^2} \tag{1-5}$$

定义新的插补数据集为$X^k=W*X+(\mathbf{1}-W)*\hat{X}^k$，$\mathbf{1}$是一个只由 1 构成的大小为$n\times p$的矩阵。其中能够观测到的数据和之前是一样的，但是有缺失的数据被正则化迭代 PCA 算法得到的拟合值替代。同时，又可以从新的矩阵中计算出M^k。

[6] Iterative PCA algorithm
[7] Regularized iterative PCA algorithm

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

步骤四：重复上述过程，直到插补后的矩阵的变化降低到一个预先设定好的阈值：

$$\sum_{ij}\left(\hat{x}_{ij}^{k-1}-\hat{x}_{ij}^{k}\right)^2 \leq \varepsilon \tag{1-6}$$

如此就能够通过迭代 PCA 算法完成缺失数据的插补。

（三）混合数据 PCA 插补

上文介绍了对连续型变量的 PCA 插补法，而对于连续变量和分类变量同时存在的数据集，需要应用混合数据 PCA 插补法，按照如下方式进行插补。

设混合数据为矩阵X，首先按照变量类型将X划分为连续变量矩阵X'和分类变量矩阵进行哑变量处理后得到的X''，即$X=(X',X'')$。然后用观测到的变量的均值作为初始值对矩阵X'进行插补，再对连续变量进行标准化。同时用哑变量各个分类的各个类别的比例填充哑变量的缺失，然后除以相关类别的个体比例的平方根，例如对于分类变量k，应除以$\sqrt{I/I_k}$。其中I_k是矩阵X''的列边缘和，等于某一分类变量第k个分类的个数。

混合 PCA 插补将基于以下加权矩阵进行主成分分析。这种特定的权重使两种变量类型的影响达到平衡，确保所有连续变量和分类变量发挥相同的作用，具体公式如下：

$$\sum_{k=1}^{K}\gamma^2(F_1,v_k)+\sum_{q=1}^{Q}\eta^2\left(F_1,v_q\right) \tag{1-7}$$

其中K和Q表示不同类型变量的个数。γ^2表示相关系数的平方，η^2是相关比率，它们均在衡量某一变量与第一主成分F_1的相关性。对加权数据矩阵应用 PCA 算法，估计得到U，Λ和V。用拟合值填补缺失值后，更新整个矩阵。重复上述过程，直到收敛。

二、基于随机森林的多重插补法

随机森林是决策树方法的一种改进算法，其利用的组合的思想，将多棵树进行整合，从而得到更加优良的预测结果的算法。不仅如此，随机森林能够处理混合类型的数据，并且在面对高维数据、复杂交互和非线性数据结构下表现的非常好。将随机森林算法应用在缺失数据的插补中就是基于随机森林的多重插补法，即本节将介绍的重点，关于随机森林的相关理论将会在本章第二节中详细介绍。

假设$x=(x_1,x_2,\dots,x_p)$是一个$n\times p$维矩阵。对于变量x_s，记$i_{mis}^{(s)}$为变量x_s中观测值缺失的个体，其中$s=1,2,\dots,p$，$i=1,2,\dots,n$。给定任意一个含有缺失值的变量x_s，可以将数据集划分成如下四个部分：

（1）变量x_s可以观测到的值，记为$y_{obs}^{(s)}$；

（2）变量x_s的缺失值，记为$y_{mis}^{(s)}$；

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

（3）除了x_s以外的其他变量中$i_{obs}^{(s)}$个体对应的值，记为$x_{obs}^{(s)}$；

（4）除了x_s以外的其他变量中$i_{mis}^{(s)}$个体对应的值，记为$x_{mis}^{(s)}$。

注意$x_{obs}^{(s)}$通常并不是全部可以观测到的，因为变量x_s中能够观测到数值的个体$i_{obs}^{(s)}$在其他变量中的观测值有可能是缺失的。同样，$x_{mis}^{(s)}$也通常不是全部缺失的，因为变量x_s中不能观测到数值的个体$i_{mis}^{(s)}$在其他变量中的观测值有可能是可以观测到的。

首先，通过平均数插补法或者其他插补方法，来填充矩阵x中的缺失值。然后，计算每个变量中的缺失值个数，按照缺失比例从小到大将变量进行排序。每一次迭代都将从缺失比例最小的变量开始进行插补。在一次迭代中，对于每个变量x_s，通过构建$y_{obs}^{(s)}$与$x_{obs}^{(s)}$的随机森林模型，将训练得到的随机森林模型应用于解释变量$x_{mis}^{(s)}$中来预测$y_{mis}^{(s)}$，然后将得到的$y_{mis}^{(s)}$更新整个矩阵，再进行变量x_{s+1}的插补。整个插补过程会重复进行，直到满足如下停止准则为止。

当新插补的数据矩阵与前一个数据矩阵在两个变量类型（连续型变量和离散型变量）上的差异首次增大时，即满足停止准则。连续型变量集合 C 的差异被定义为：

$$\Delta C = \frac{\sum_{j\in C}(x_{new}^{imp} - x_{old}^{imp})^2}{\sum_{j\in C}(x_{new}^{imp})^2} \tag{1-8}$$

其中，x_{new}^{imp}表示新插补的数据矩阵，x_{old}^{imp}表示前一个插补的数据矩阵。对于离散型变量集合D的差异被定义为：

$$\Delta D = \frac{\sum_{j\in D}\sum_{i=1}^{n} I(x_{new}^{imp} \neq x_{old}^{imp})}{NA_cnt} \tag{1-9}$$

其中，NA_cnt表示离散型变量中缺失值的数量，$I(\cdot)$是示性函数。

对缺失值进行插补后，使用归一化均方根误差对性能进行评估。对于连续型变量，其定义为：

$$NRMSE = \sqrt{\frac{MEAN((X^{true} - X^{imp})^2)}{VAR(X^{true})}} \tag{1-10}$$

其中X^{true}是完整的数据矩阵，X^{imp}是插补后的数据矩阵。我们用$MEAN$和VAR表示对连续型变量的经验平均值和方差。对于离散型变量，我们使用错误分类在缺失值上的比例。在这两种情况下，$NRMSE$越接近于 0 表示预测能力越好，越接近于 1 表示预测能力糟糕。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

三、SAEM 法

SAEM 法[8]是由 Wei Jiang、Julie Josse 等人于 2020 年提出的一种基于 MH 抽样[9]，对不完整数据进行 Logistic 回归的插补法。该方法在插补时，不仅利用了观测到的解释变量的信息，还利用了响应变量的信息，因此插补效果更好。此外该方法能够应用于混合型数据，并且可以同时得到插补结果和估计结果，下面分别介绍其缺失值插补过程和预测过程。

（一）插补和模型参数估计过程

对于一个经典的 EM 插值法，给定初始值θ_0，第k次迭代遵循以下两个步骤完成θ_{k-1}到θ_k的更新。

E 步：计算期望

$$Q_k(\theta) = E[LL(\theta; x, y)|x_{obs}, y; \theta_{k-1}] \tag{1-11}$$
$$= \int LL(\theta; x, y)p(x_{mis}|x_{obs}, y; \theta_{k-1})dx_{mis}$$

M 步：更新θ的估计值

$$\theta_k = argmax_\theta Q_k(\theta) \tag{1-12}$$

由于 E 步中关于 Logistic 回归模型的期望没有显式的表达，因此需要用到 MCEM 方法。在 E 步，MCEM 能够从目标分布$p(x_{mis}|x_{obs}, y; \theta_{k-1})$中产生许多缺失数据的样本，然后用一个经验平均代替完整数据集计算出的对数似然的期望。但是 E 步的精确蒙塔卡罗近似值可能需要大量的计算。

为了提升计算效率，SAEM 算法采用随机逼近来替换 E 步。从初始值θ_0开始，第k次迭代遵循以下三个步骤：

第一步：对$i = 1,2, \dots, n$，从如下分布中抽出$x_{i,mis}^{(k)}$

$$p\left(x_{i,mis}\middle|x_{i,obs}, y_i; \theta_{k-1}\right) \tag{1-13}$$

第二步：进行随机逼近。用如下规则更新函数Q

$$Q_k(\theta) = Q_{k-1}(\theta) + \gamma_k\left(LL\left(\theta; x_{obs}, x_{mis}^{(k)}, y\right) - Q_{k-1}(\theta)\right) \tag{1-14}$$

其中(γ_k)是一个非增的正数序列。

第三步：最大化。用如下规则更新θ的估计值

$$\theta_k = argmax_\theta Q_k(\theta) \tag{1-15}$$

在第二步中，序列(γ_k)的选择非常重要，是 SAEM 算法能够收敛到最大观察似然的保障。

在 Logistic 回归中，未观测到的数据通常不能准确地从条件分布（1-13）中得出，

[8] Stochastic approximation version of the EM algorithm, SAEM
[9] Metopolis Hasting 抽样

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

它依赖于一个不可用封闭形式计算的积分。一种解决方案是使用 Metropolis Hastings 算法，该算法包括构造一个以目标分布为平稳分布的马尔可夫链。然后使用S次迭代后链的状态作为目标分布的样本。为了定义 MH 算法的建议分布，我们观察到目标分布可以分解如下：

$$p\left(x_{i,mis}\middle|x_{i,obs},y_i;\theta\right)\propto p(y_i|x_i;\beta)p\left(x_{i,mis}\middle|x_{i,obs};\mu,\Sigma\right) \tag{1-16}$$

我们选择第二个部分$p(x_{i,mis}|x_{i,obs};\mu,\Sigma)$作为建议分布，它是一个正态分布

$$x_{i,mis}|x_{i,obs}\sim N_p(\mu_i,\Sigma_i) \tag{1-17}$$

其中：

$$\mu_i=\mu_{i,mis}+\Sigma_{i,mis,obs}\Sigma_{i,obs,obs}^{-1}\left(x_{i,obs}-\mu_{i,obs}\right) \tag{1-18}$$

$$\Sigma_i=\Sigma_{i,mis,mis}+\Sigma_{i,mis,obs}\Sigma_{i,obs,obs}^{-1}\Sigma_{i,obs,mis} \tag{1-19}$$

$\mu_{i,mis}$是个体i的关于μ的缺失元素。协方差矩阵Σ也是用同样的方式进行分解。

（二）预测过程

设$\tilde{x}=(\tilde{x}_{obs},\tilde{x}_{mis})$是测试集中的一个观测值，$\tilde{y}$是二维响应变量，即我们要预测的值。需要注意的是，测试集中也包含着缺失值，因此我们不能直接将拟合好的模型直接应用于含有缺失值的测试集来预测$\tilde{y}$。为解决这个问题，我们需要在给定观察数据的情况下排除有缺失的的协变量。考虑如下蒙特卡洛样本：

$$\left(\tilde{x}_{mis}^{(s)},1\le s\le S\right)\sim p(\tilde{x}_{mis}|\tilde{x}_{obs}) \tag{1-20}$$

给定观测到的数据，可以通过最大化其分布边缘化的缺失数据来直接估计出响应变量：

$$\hat{y}=argmax_{\tilde{y}}p(y|\tilde{x}_{obs})=argmax_{\tilde{y}}\int p(y|\tilde{x})\ p(\tilde{x}_{mis}|\tilde{x}_{obs})d\tilde{x}_{mis} \tag{1-21}$$

$$=argmax_{\tilde{y}}\mathbb{E}_{p_{\tilde{x}_{mis}|\tilde{x}_{obs}}}p(\tilde{y}|\tilde{x})=argmax_{\tilde{y}}\sum_{s=1}^{S}p(\tilde{y}|\tilde{x}_{obs},\tilde{x}_{mis}^{(s)})$$

第二节　机器学习方法概述

一、随机森林

随机森林采用 bootstrap 重抽样方法来生成采样，然后对每个采样样本分别建立决策树，再去训练每个基学习器，它可以用于不同类型的问题中。对于分类问题，根据每个基学习器的分类结果进行选举，选票最多的一类做为随最终的分类结果。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

对于另外一种问题，对基学习器预测值进行平均，用均值作为输出结果。下面，先从随机森林的基本单元决策树出发进行理论介绍。

（一）集成学习

为了减少预测的方差、偏差等，提升模型的准确性，学者们将不同的预测模型整合在一起，这就产生了集成学习的方法。

集成学习主要包含以下三中类型：第一种是并行式集成学习，这种集成学习中构成集成的各个模型是相互独立生成的，也就是说其中的弱分类器的训练或生成是并行产生的。其中最著名的算法便是 bagging。第二种是顺序集成学习，其中的学习器是按顺序产生的，并且相互依赖，也就是说其中的弱分类器一次只能训练一个，因为下一个模型将需要来自它的上游训练的信息。第三种堆叠集成学习，与前两种方法不同的是，这种方法需要首先用多个不同类型的分类器，或者多个参数不同的模型进行预测，然后再将这些分类器的预测结果作为特征集输入，对得到的特征集进行训练输出最终的结果。

随机森林算法依赖于一种称为“bagging”的并行集成方法来生成弱分类器。bagging 是 boostrap aggregation 的一个通俗术语，它允许我们通过对总体随机子样本测量的多个估计值进行平均来减少估计值的方差。bagging 的第一部分是应用 bootstrap 抽样来获取数据子集。这些子集随后被输入到一个模型中，该模型将构成最终的集成方法。在所有的模型都建立好之后，它们的输出必须为更大的模型聚合成一个单一的相干预测。在分类器模型的情况下，通常是哪个类别获得最多的选票则是最终预测的结果。对于回归问题，则使用预测结果值的简单平均值。其算法实现过程如下。

给定样本集$D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$和算法$G(x)$，首先进行基分类器的训练，对于$t = 1,2, \dots, T$，其中$T$表示弱分类器的迭代次数，进行如下步骤：

第一步，对训练集进行第t次随机抽取，抽取过程需要重复n次，可以得到一个包含n个样本的采样集D_t。

第二步，利用采样集D_t训练第t个弱学习器$G_t(x)$。

如此就可以得到了T个弱分类器，然后分别对分类或回归问题采取最大投票数或取平均值。

（二）随机森林

随机森林的“森林”一词意味着其在集成学习时使用的弱分类器为决策树，并且能够克服使用单个决策树预测时常常出现高方差和低偏差的缺陷，有效减少过拟合。

随机森林利用了 bagging 的思想，并在此基础上增加了特征 bagging。特征 bagging 又称为随机子空间方法，也是一种集成方法。它应用于数据集的特征，即数

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

据集的列而不是行。它被用来作为一种减少特征之间的相关性的方法，训练时使用数据集特征的随机子集的基预测器，而不是每次使用完整的特征空间。图 1-1 展示了 bagging（左图）和随机森林（右图）在构建基分类器时所选取的样本和特征的区别。每一个小格子都代表着一个样本在某个特征处的数值。图中每种集成学习方法都画出了两个用于构建基分类器的样本集，分别用红色和蓝色的阴影表示。可以看出，bagging 的两个采样样本取出了整个数据集的部分样本及其全部特征，而随机森林则取出了整个数据集的部分样本和其部分特征，并且每次取出的特征不完全相同。

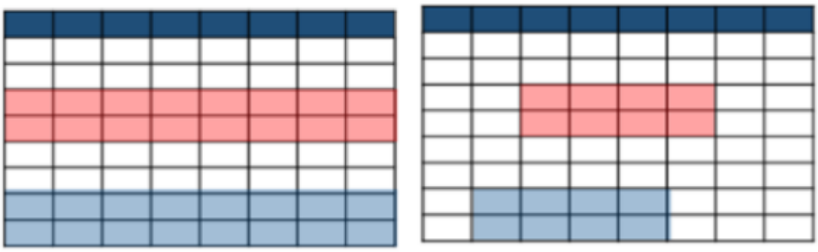

图 1-1 bagging（左）和随机森林（右）的对比

随机森林的建模和预测步骤可以概括如下：

首先，设定随机森林中的树个数为 m，每个树中使用到的样本数 n，每个决策树中使用到的特征数 k。

（1）对训练集进行随机抽取，每次只抽取 1 个样本，重复 n 次，最终得到一个包含 n 个样本的样本集。

（2）对特征集进行上述相同的随机抽样，最终得到一个包含 k 个特征数的特征集。

（3）记（1）（2）中得到的样本为x_i，并对其建立 CART 决策树模型。

（4）重复上述过程 m 次，最终可以得到 m 棵决策树，记第 i 棵决策树的预测结果为$C_i(x_i)$。

（5）如果这是一个分类问题，那么最终的预测结果为$C_i(x_i)$中票数最多的。否则，最终的预测结果为$\frac{1}{m}\sum_{i=1}^{m} C_i(x_i)$，即取平均值。

（三）特征重要性

本文研究将使用五百多个特征来进行阿尔兹海默症的预测，我们希望能够找出诸多变量当中对阿尔兹海默症最具解释力的特征，对引发阿尔兹海默症的危险因素提前进行干预。下面介绍用随机森林来计算特征重要性。其思想是计算每个特征在随机森林中的每颗树上的贡献，然后对不同特征对随机森林的贡献大小进行对比。这一贡献大小有不同的衡量标准，常用的有基尼系数以及袋外数据错误率。本文将

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

利用基尼指数来计算变量重要性评分（VIM[10]）。假设有p个特征$X_1, X_2, \dots, X_p$，则每个特征X_j的基尼指数评分为$VIM_j^{(Gini)}$，具体计算方法如下。

计算每个分支节点 m 的基尼指数，记为GI_m，其计算公式如（1-22）所示：

$$GI_m = 1 - \sum_{k=1}^{K} p_{mk}^2 \tag{1-22}$$

其中，K表示类别的个数，p_{mk}表示分裂节点 m 中第 k 个类别所占的比例。特征X_j在节点 m 的重要性为公式（1-23）所示。

$$VIM_{jm}^{(Gini)} = GI_m - GI_l - GI_r \tag{1-23}$$

其中，GI_l和GI_r分别对应分枝后两个新节点的基尼指数。特征X_j在第 i 棵决策树上的重要性可以用如下的方式来表达，设 M 为X_j在树i中出现的节点集合，那么

$$VIM_{ij}^{(Gini)} = \sum_{m \in M} VIM_{jm}^{(Gini)} \tag{1-24}$$

设随机森林中决策树的个数为 n，那么特征X_j在整个随机森林中的重要性评分为

$$VIM_j^{(Gini)} = \frac{\sum_{j=1}^{n} VIM_{ij}^{(Gini)}}{\sum_{i=1}^{p} \sum_{j=1}^{n} VIM_{ij}^{(Gini)}} \tag{1-25}$$

二、Logistic 回归

Logistic 回归也是一种常见的机器学习方法，虽然它叫做回归，但是通常被用来解决二分类问题，可以估计出某件事发生的概率。Logistic 回归是广义线性回归的一种，该方法是在传统线性回归模型的基础上发展起来的。在二分类问题中，利用形式如$\mathrm{p(X)} = \beta_0 + \beta_1 X$的线性回归模型进行预测时，所得到的概率有可能大于 1 也有可能小于 0，这是不符合概率的性质的。而 Logistic 回归能够通过 sigmoid 函数引入非线性因素，因此可以把输出限制在 0 到 1 之间，从而轻松处理二分类问题。

（一）Logistic 回归模型设定

首先介绍 sigmoid 函数[11]，其形式如（1-26）所示：

$$g(z) = \frac{1}{1 + e^{-z}} \tag{1-26}$$

其函数曲线如下图所示：

[10] Variable importance measures, VIM
[11] 也称为逻辑函数。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

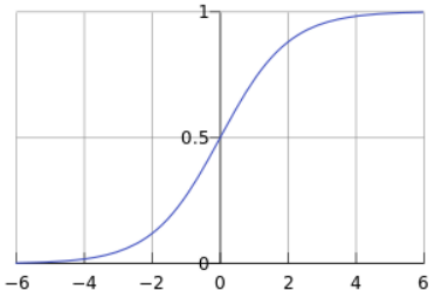

图 1-2 sigmoid 函数图像

从上图可知该函数是一个 s 形曲线，该函数的最大值和最小值分别为 1 和 0，离 y 轴越远该函数的值会越接近其上界和下界。

逻辑回归的假设函数形式为$h_\theta(x) = g(\theta^T x)$，即：

$$h_\theta(x) = \frac{1}{1 + e^{-\theta^T x}} \tag{1-27}$$

其中x是输入，θ为待估参数。

逻辑回归模型的假设如下式所示：

$$P(y = 1|x;\theta) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}} \tag{1-28}$$

表示在给定x和θ的条件下$y = 1$的概率。这里$g(h)$就是我们上面提到的 sigmoid 函数，与之相对应的决策函数为：

$$y^* = I(P(y = 1|x) > 0.5) \tag{1-29}$$

其中$I(\cdot)$是示性函数。通过（1-29）式，就可以给出样本的类别。

一般情况下，我们会选择选择$1/2$作为阈值，但是在更多地实际应用场景下，根据不同的情况，也可以选择不同阈值，比如说，当对于正例的召回率要求高的时候，我们更倾向于阈值小一些。

（二）Logistic 回归的求解

当我们确定了模型h，后面做的所有事情就是训练模型的参数θ。上式的似然函数为：

$$L(\theta) = \prod_{i=1}^{m} \left(h_\theta(x_i)\right)^{y_i} (1 - h_\theta(x_i))^{1-y_i} \tag{1-30}$$

为求解使这一似然函数的值最大时的参数估计，对上式先取对数：

$$lnL(\theta) = \sum_{i=1}^{m} \left(y_i ln(x_i)\right) + (1 - y_i)\ln\left(1 - h_\theta(x_i)\right) \tag{1-31}$$

考虑$lnL(\theta)$中间一部分，对θ_k求导可以得到：

$$\frac{\partial lnL(\theta_k)}{\partial \theta_k} = \sum_{i=1}^{m} x_{ik}(h_\theta(x_i) - y_i) = 0 \tag{1-32}$$

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

使用梯度上升法求解参数θ，其迭代公式为：

$$\theta = \theta + \alpha \nabla lnL(\theta) = \theta + \alpha \frac{\partial lnL(\theta)}{\partial \theta} \tag{1-33}$$

最终可以得到参数的计算公式：

$$\theta = \theta + \alpha \sum_{i=1}^{m} x_{ik}(h_\theta(x_i) - y_i) \tag{1-34}$$

三、支持向量机

支持向量机的基本模型是一个线性分类器，其优化的最终目标找到一个超平面，保证间隔最大化。

（一）间隔与支持向量

对于二分类问题，想要把数据区分开，那么最传统的想法就是用一个“平板”，将数据隔开，这个平板，在多维数据当中被称为超平面，其方程可如下表示

$$w^T x + b = 0 \tag{1-35}$$

其中参数w和b已知，且可以确定出唯一超平面(w, b)，其中任意一个样本在样本空间的点记为x到超平面的距离为：

$$r = \frac{|w^T x + b|}{\|w\|} \tag{1-36}$$

在超平面$w^T x + b = 0$确定的情况下，$|w^T x + b|$代表点x距离超平面的远近。当$w^T x + b > 0$时，表示 x 在超平面的一侧[12]，而当$w^T x + b < 0$时，则表示 x 在超平面的另外一侧[13]。因此，$(w^T \mathrm{x}^* + b)\mathrm{y}^*$ 的正负性恰能表示数据点x^*是否被分类正确。

我们把位于$w^T x + b = 1$或$w^T x + b = -1$上的数据点，称为支持向量。显然，对于所有的这样的向量，它们恰好满足$(w^T \mathrm{x}^* + b)\mathrm{y}^* = 1$。它们到超平面的距离之和叫做间隔，即：

$$r = \frac{2}{\|w\|} \tag{1-37}$$

[12] 记为正类，类标为 1
[13] 记为负类，类别为-1

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

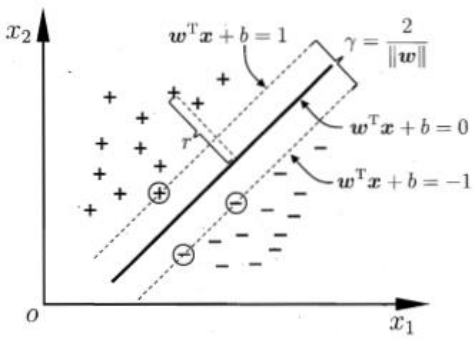

图 1-3 支持向量与间隔[14]

支持向量机的目的就是希望找到一个划分超平面，满足间隔最大化。即找到满足约束的参数w和b使得r最大

$$max_{w,b}\frac{2}{\|w\|}\quad s.t.\ \ y_i(w^Tx_i+b)\geq 1,\ \ i=1,2,\dots,m \tag{1-38}$$

上述约束等价于

$$min_{w,b}\frac{1}{2}\|w\|^2\quad s.t.\ \ y_i(w^Tx_i+b)\geq 1,\ \ i=1,2,\dots,m \tag{1-39}$$

这就是支持向量机的基本型。

（二）SVM 优化

上节得到了 SVM 优化的主问题如（1-37）式所示，那么求解线性可分的 SVM 的步骤为：

步骤一：构造拉格朗日函数：

$$min_{w,b}max_{\lambda}L(w,b,\lambda)=\frac{1}{2}\|w\|^2+\sum_{i=1}^{n}\lambda_i\big(1-\ y_i(w^Tx_i+b)\big) \tag{1-40}$$

$$s.t.\ \lambda_i\geq 0$$

步骤二：利用强对偶性转化：

$$max_{\lambda}min_{w,b}L(w,b,\lambda) \tag{1-41}$$

对参数w和b求偏导数：

$$\begin{cases}\dfrac{\partial L}{\partial w}=w-\displaystyle\sum_{i=1}^{n}\lambda_i x_i y_i=0\\[2ex] \dfrac{\partial L}{\partial b}=\displaystyle\sum_{i=1}^{n}\lambda_i y_i=0\end{cases} \tag{1-42}$$

得到：

[14] 周志华.机器学习[M].北京:清华大学出版社.2012.122 页

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

$$\begin{cases} \sum_{i=1}^{n} \lambda_i x_i y_i = w \\ \sum_{i=1}^{n} \lambda_i y_i = 0 \end{cases} \tag{1-43}$$

将结果进行回代，得到：

$$min_{w,b} L(w,b,\lambda) = \sum_{j=1}^{n} \lambda_i - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) \tag{1-44}$$

步骤三：由上一步得：

$$max_{\lambda} \left(\sum_{j=1}^{n} \lambda_i - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) \right) \tag{1-45}$$

$$s.t. \sum_{i=1}^{n} \lambda_i y_i = 0, \lambda_i \geq 0$$

如此就将问题转化成了一个二次规划问题，可以选择序列最小优化算法（SMO[15]）来进行求解，其基本原理是每次只对一个参数进行优化，且在优化这一参数的期间固定住其他参数的值不变，求出当前这一参数的局部最优解。由于这一个凸优化问题的限制的约束条件为$\sum_{i=1}^{n} \lambda_i y_i = 0$，因此无法在每次优化中只选择一个参数，所以下需要进行如下变换。

（1）一次选择两个需要更新的参数λ_i和λ_j，固定其他参数。于是约束就变成了：

$$\lambda_i y_i + \lambda_j y_j = c \tag{1-46}$$

其中，$\lambda_i \geq 0$，$\lambda_j \geq 0$，$c = -\sum_{k \neq i,j} \lambda_k y_k$，由此可得：

$$\lambda_j = \frac{c - \lambda_i y_i}{y_i} \tag{1-47}$$

也就是说我们可以用λ_i的表达式代替λ_j。这样就相当于把目标问题转化成了仅有一个约束条件的最优化问题，仅有的约束是$\lambda_i \geq 0$。

（2）对于仅有一个约束条件的最优化问题，我们完全可以在λ_i上对优化目标求偏导，令导数为零，从而求出变量值λ_{inew}，然后根据λ_{inew}求出λ_{jnew}。

（3）如果要收敛，需要多次迭代。最终可通过 SMO 这一方法求得所需要最优解λ^*。

步骤四：我们求偏导数时得到：

[15] Sequential Minimal Optimization, SMO

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

$$w = \sum_{i=1}^{m} \lambda_i y_i x_i \tag{1-48}$$

由上式可求得w。我们知道所有$\lambda_i > 0$对应的点都是支持向量，我们可以随便找个支持向量，然后带入$y_S(w^T x_S + b) = 1$，求出b即可。两边同乘y_S，得$y_S^2(w^T x_S + b) = y_S$。因为$y_S^2 = 1$，所以$b = y_S - w^T x_S$。为了更具鲁棒性，我们可以求得支持向量的均值：

$$b = \frac{1}{|S|} \sum_{s \in S} (y_S - w^T x_S) \tag{1-49}$$

步骤五：w和b都已经求出，那么我们就可以确定出超平面$w^T x + b = 0$，分类决策函数为：

$$f(x) = sgn(w^T x + b) \tag{1-50}$$

将新样本点导入到决策函数中既可得到样本的分类。

（三）核函数

事实上仅有极少的数据集能偶满足线性可分，当处理非线性可分的情况时，核函数能帮助我们很好的解决这一问题，它可以将输入向量映射到更高维度的空间，使新生成的向量线性可分，假设原始向量为 x，映射之后的向量为 z，那么映射关系为：

$$z = \varphi(x) \tag{1-51}$$

实际操作过程中，使用先映射后做内积的方法：

$$K(x_i, x_j) = K({x_i}^T x_j) = \varphi(x_i)^T \varphi(x_j) \tag{1-52}$$

其中，常见的核函数如表 1-1 所示。

表 1-1 常见的核函数

核函数	计算公式
线性核	$K(x_i, x_j) = {x_i}^T x_j$
多项式核	$K(x_i, x_j) = (\gamma {x_i}^T x_j + b)^d$
高斯核	$K(x_i, x_j) = \exp(-\gamma \lVert x_i - x_j \rVert^2)$
sigmoid 核	$K(x_i, x_j) = \tanh(\gamma {x_i}^T x_j + b)$

其中γ，b，d是在调参过程中人为控制的参数。

使用核函数映射后，求解以下问题为：

$$min_\alpha \frac{1}{2} \sum_{i=1}^{l} \sum_{j=1}^{l} \alpha_i \alpha_j y_i y_j K({x_i}^T x_j) - \sum_{k=1}^{l} \alpha_k \tag{1-53}$$

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

$$s.t. 0 \leq \alpha_i \leq C, \sum_{j=1}^{l} \alpha_j y_j = 0$$

其中，l为训练集样本数，C为惩罚因子，一般要大于 0。在训练模型时，核函数选择高斯核时需要调整参数为γ。选择多项式核时需要调整的参数为γ，b，以及d。惩罚因子 C 需要人工指定。最终预测时的分类判别函数为：

$$sgn\left(\sum_{i=1}^{l} \alpha_i y_i K({x_i}^T x) + b\right) \tag{1-54}$$

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

第二章　数据介绍与描述性统计

第一节　数据来源与描述性统计

一、数据来源

本文研究的数据来自 ADNI 数据库[16]，是一项致力于研究和开发减缓或停止阿尔兹海默症病情进展的治疗方法的全球性研究。ADNI 是世界上第一个阿尔茨海默病大数据项目，由多家美国研究机构和组织于 2003 年耗资 6000 万美元发起。这项大型研究的主要目标是测试系列核磁共振成像、正电子发射断层扫描、其他生物标记、临床和神经心理评估能否结合起来评估轻度认知障碍和早期阿尔茨海默病的进展。

ADNI 研究在多站点多个时间点收集不同病情发展阶段人群的核磁共振图像、临床指标、基因数据、认知测评得分、实验室数据和正电子发射型计算机断层显像等。人群分为以下三类，健康对照组（CN[17]）、轻度认知障碍（MCI[18]）和阿尔茨海默症患者（AD[19]）。阿尔兹海默症的患病过程是从正常人逐渐发展为痴呆的，因此在两者之间的过渡阶段被定义为轻度认知障碍。这一阶段如果能尽早发现患者病征，就能够及时采取干预措施来延缓痴呆的进一步恶化。因此这一中间过渡阶段的识别意义重大。

ADNI 计划招募大约 800 名不同病情阶段的成年人参加实验研究，其年龄分布在 55 岁以上，其中有 200 名左右的认知正常的老年人、约 400 名左右的 MCI 患者以及 200 名左右的早期 AD 患者。ADNI 组织会对这些实验追踪目标持续寻访 2 到 3 年，每隔 6 个月进行一次评估其症状状态。若追踪寻访实验对象达到 24 个月，之后每年进行一次评估。从 ADNI-GO 开始，每期的研究对象不仅包括新招募的人员，还有前期研究中继续参与研究的人员。目前为止已经成功进行了 ADNI1、ADNI-GO、ADNI2 三期研究，当前正处在 ADNI3 阶段。距今为止，约 1500 多名来自美国和加拿大多个不同的地区的受试者参与了研究。

二、数据描述性统计

本文将使用 ADNI 数据库中的基线数据进行阿尔兹海默症的诊断，数据于 2020 年 1 月 1 日在 ADNI 官方网站[20]获得，原始数据集包含 3887 个个体。本文对原始数据的样本量和变量均做了一定的删减，具体操作如下。由于 ADNI3 时期中许多新增

[16] 阿尔茨海默症神经成像组织（Alzheimer's Disease Neuroimaging Initiative, ADNI）
[17] Cognitively normal subjects, CN
[18] Mild cognitive impairment, MCI
[19] Alzheimer’s disease dementia, AD
[20] ADNI 数据库官网：www.adni-info.org

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

测试与 ADNI1、ADNI-GO、ADNI2 时期不对应，并且 ADNI3 中由于网站数据更新滞后存在大量的数据缺失，因此本文剔除了所有 ADNI3 时期的研究样本。同时，本文用于阿尔兹海默症病情诊断的响应变量，也存在部分个体缺失，对此也进行了样本剔除。此外，为保证数据插补的效果，本文剔除了缺失比例在 45%以上的变量，同时删除了方差为 0 的变量。最终得到了一个包含 1730 个受试者和 533 个变量的数据集，这一数据集将用于后续的建模分析。这一数据集的变量缺失比例在 0 到 45%，其中不含缺失的变量个数为 57 个，占变量数的 10.69%，含缺失的变量个数为 476 个，占比 89.31%。绘制含缺失数据变量的缺失比例，其分布如图 2-1 所示。可以看出绝大部分变量的缺失比例在 0 到 5%之间，占总变量个数的 67.73%。

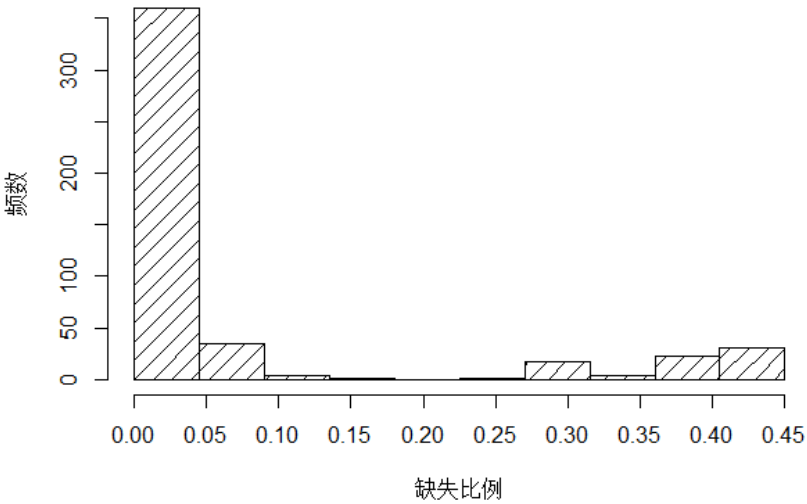

图 2-1 含缺失变量的缺失比例分布

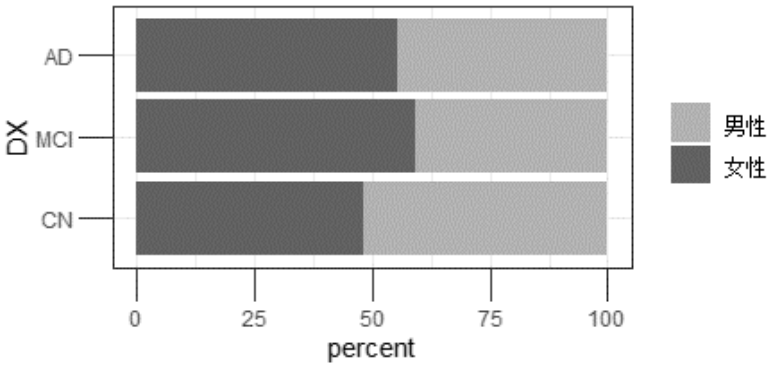

图 2-2 受试者性别的分布

该数据集中包含着 523 名 CN，866 名 MCI 和 341 名 AD，平均年龄为 73.59 岁，50%的年龄集中在 68 到 79 岁之间。其中 954 名为男性，占比 55.14%，其余为女性。绘制性别和病情阶段的百分比堆积条形图，查看不同病情类别中的性别比例情况，如图 2-2 所示。可以看出，在 CN 人群中，男性与女性的比例相当，分别为 51.63%和 48.37%。而在 MCI 和 AD 中，女性的比例分别超过男性 18.24 和 10.85 个百分点。这可能预示着女性更容易患阿尔兹海默症。受试者中有 1401 人已经退休，占比 80.98%，

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

305 人仍然在职业劳动，占比 17.63%，24 人数据缺失，占比 1.41%。

图 2-2 展示了三类人群中是否退休的比例。可以看出，AD 群体中，已退休人员的比例比 MCI 和 CN 群体大约高 11 个百分点，在一定程度上预示着劳动能够降低痴呆的风险。受试者中有 75.38%的人已婚，12.31%的人丧偶，8.61%离婚，3.70%未婚。从图 2-3 中可以看出，CN 组、MCI 组、AD 组的已婚比例依次升高，无伴侣状态的比例依次降低。这可能预示着婚姻可能会增加患阿尔兹海默症的风险。

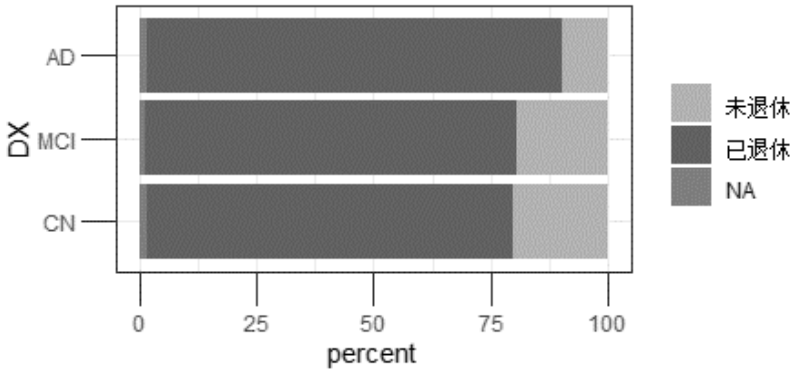

图 2-3 受试者是否退休的分布

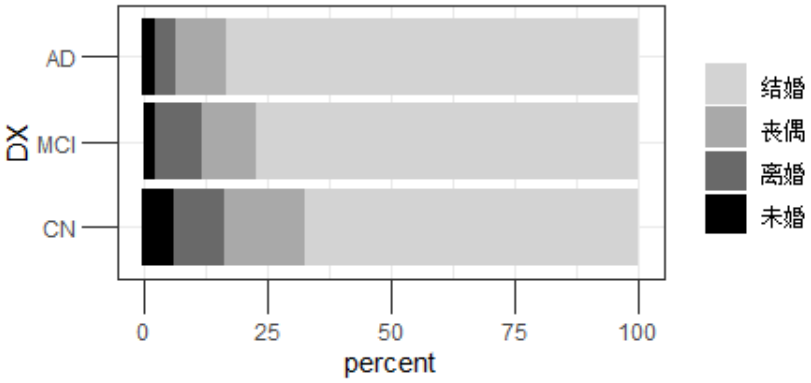

图 2-4 受试者的婚姻情况

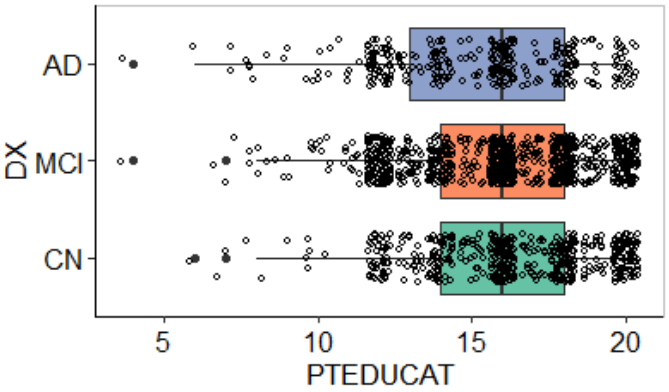

图 2-5 受试者受教育年限的分布

图 2-5 展示了受教育年限在三类人群中的分布。可以看出，受试者的平均受教育年限为 15.91 年，50%受试者的受教育年限集中在 14 到 18 年之间。此外，三个群体

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

的受教育年限中位数均在 16 年左右，下四分位数均在 18 年左右。然而 AD 群体的上四分位数比 MCI 群体和 CN 群体更低，且 AD 群体受教育年限的分布更加左偏，离群点更多。说明 AD 群体中，受教育年限时长低的人更多。这可能预示着受教育年限越低，患阿尔兹海默症的可能性越高。

以上从描述统计角度展示了几个变量的取值水平与患阿尔兹海默症的关系。本文使用到的数据集中的变量主要包括以下几个部分：（1）临床数据；（2）认知能力评估；（3）CSF[21]数据；（4）MRI[22]成像数据；（5）PET[23]成像数据；（6）人口统计学；（7）疾病史。部分变量如下表所示。

表 2-1 本文用到的部分变量

变量分类	变量
人口统计学	性别；人种；语言类别；婚姻状况；职业类型；居住地区类型；受教育年限；是否退休；父亲、母亲、兄弟姐妹是否痴呆；
不良史	是否有精神病学、神经学、头、眼、耳、鼻、喉、心血管、肌肉骨骼、肝、肠胃、过敏、恶性肿瘤等病史； 有无吸烟、酒精滥用、药物滥用等不良习惯史；
神经系统检查	是否有视觉、听觉障碍的障碍；是否有手指到鼻子、脚跟到胫骨、深部腱反射、足底反射、步态等神经系统问题
常规体检项目	是否有一般外观、头、眼、耳、鼻、喉、脖子、胸部、心、腹部、四肢、水肿、外周血管、皮肤及附件、肌肉骨骼等问题； 血压、身高、体重、体温、坐位脉搏率、呼吸频率；
不良事件	是否与慢性病、腰椎穿刺、成像程序有关； 是否危及生命、延长住院时间、导致死亡；
认知和功能测验	神经心理学测验；生活能力评分；抑郁评分；认知评分；记忆力测试评分等；
临床数据	代谢趋缓指数；总胆红素、血清葡萄糖、血清总蛋白、肌酸激酶等； 鹅去氧胆酸、脱氧胆酸、糖醛酸去氧胆酸、牛去氧胆酸等； Aβ 蛋白、Aβ42 蛋白、Aβ40 蛋白、Aβ38、Tau 蛋白、pTau 蛋白；
成像数据	右前扣带皮层体积(皮质分裂)/表面积/皮层厚度平均值/标准偏差； 颞上方的表面积/皮质厚度平均值/皮质厚度标准偏差； 右颏上体积(皮质分裂)/表面积/皮质厚度等 341 个变量

[21] 脑脊液（Cerebrospinal fluid, CSF）
[22] 核磁共振成像（Magnetic resonance imaging, MRI）
[23] 正电子发射断层扫描（Positron emission tomography, PET）

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

第二节　数据预处理

由于轻度认知障碍患者病情发展为痴呆的风险较高，这部分人群也需要重点关注。据某项研究显示，每年几乎每十个轻度认知障碍患者就会有一个人进一步发展成痴呆。因此轻度认知障碍这一阶段的提早发现引起了越来越多的关注，因为它提供了一个早期靶向疾病过程的机会。因此本文在分类时，以 CN 人群为 0，MCI 和 AD 人群为 1。目标在于尽可能识别出早期痴呆迹象，以提早进行干预，以免痴呆程度恶化。在进行建模前，需要对数据进行预处理。本文的数据预处理过程主要包括了两部分，分别是离散变量的哑变量处理和数据的归一化。

一、哑变量处理

本文收集到的变量有一部分为离散变量，例如从人口统计学、各项人体检查中收集到的变量。为了处理这些离散数据我们需要对这类数据进行哑变量处理，哑变量处理后这些变量便增加了多个二元特征，起到了增加特征数量的作用。哑变量处理有两种方式，分别是使用 N-1 位状态储存器或者 N 位状态储存器对 N 个状态进行编码。由于本文使用到的模型有 Logistic 回归，该模型对多重共线性十分敏感。而采用第二种哑变量处理方式将会引起完全多重共线性，因此这里选择第一种处理方式。

二、归一化

Logistic 回归模型有一个缺点就是当数据量纲不一致时，量纲大的变量会在模型中占据较大的解释份额，对预测结果造成一定影响。为了消除这种影响我们需要运用以下方法处理数据，具体公式为：

$$x^* = \frac{x - \bar{x}}{S_x} \tag{2-1}$$

其中$\bar{x}$为变量x的均值，S_x为变量x的标准差，x^*为归一化后的值。经过处理后的数据均值为 0，方差为 1。

第三节　模型评价指标

对数据进行预处理后，接下来将运用机器学习模型来进行阿尔兹海默症诊断。这是一个典型的分类问题，常见的评价指标有准确率、精确率、召回率、特异度、AUC 值等，下面将展开介绍。

一、准确率、精确率、召回率、特异度

要计算常见的这些机器学习评价指标，需要用到混淆矩阵，对于一个二分类问题，

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

我们可以得到如表 2-2 所示的混淆矩阵。

混淆矩阵直观展示了一个模型在正负两个类别上的分类情况。其中，TP[24]表示真实为正预测为正。FN[25]表示真实为正预测为负。FP[26]表示真实为负预测为正。TN[27]表示真实为负预测为负。以阿尔兹海默症诊断为例，正类表示患病，负类表示健康，则 TP 表示患有阿尔兹海默症并且模型预测的类别也为患病，FP 表示没有患有阿尔兹海默症但是被诊断为患病，FN 表示患有阿尔兹海默症但是被诊断为没有患病，TN 表示没有患有阿尔兹海默症并且诊断类别也是没患病。

表 2-2 混淆矩阵

		真实类别	
		正类	负类
预测类别	正类	TP	FP
	负类	FN	TN

准确率计算公式如（2-2）所示，表示判别结果中，有多少预测结果和实际是相符的。

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{2-2}$$

另外需要注意到当数据集类别不平衡时，准确度并不能完全说明模型性能的高低。例如两个类别样本数量差距太大时，那么模型对于样本量占比大的类别的预测准确率会非常高，但实际上该模型对于样本量小的数据类型没有进行区分，因此数据集样本数量不平衡可能会导致样例被错误分类。

另外本文注意到对样本进行分类时，对样本进行分类的结果的重要程度是不能忽略的，例如我们对一定数量的人群进行核酸检测，我们希望不漏掉任何一个阳性样本，还有在短信信息智能过滤时，我们不希望重要的通知信息被误判为垃圾短信。所以当样本在分类时某个类别的重要程度要高于其他类别时，通常会使用下面要介绍的精确率和召回率作为判断评估模型性能的指标。

精确率计算公式如（2-3）所示，表示在预测为正类的样本中真实类别为正类的样本所占比例。

$$precision = \frac{TP}{TP + FP} \tag{2-3}$$

召回率[28]计算公式如（2-4）所示，表示在真实为正类的样本中模型所输出的被预测为正的样本所占的比重。

[24] 真阳（true positive, TP）
[25] 假阴（false negative, FN）
[26] 假阳（false positive, FP）
[27] 真阴（true negative, TN）
[28] 又称灵敏度、查全率。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

$$sensitivity = \frac{TP}{TP + FN} \tag{2-4}$$

召回率的大小只受真实情况下是正类样本的影响，而与真实为负类的样本无关，而精确率则会受到两类样本的影响。

特异度计算公式如（2-5）所示，表示在所有真实为负类的样本中，被预测为负类的比例。

$$specificity = \frac{TN}{TN + FP} \tag{2-5}$$

二、ROC 曲线与 AUC 值

ROC 曲线[29]常被用来评价一个二值分类器的优劣，这一工具可以有效地用于度量分类中的非均衡性的工具。其原理是给出多个不同的从 0 到 1 的阈值，然后以不同阈值作为判别的标准，根据模型预测得到的概率和阈值得到一次预测结果，给出每次结果下的一系列特异性[30]和灵敏度[31]，其横坐标为 FPR，纵坐标为 TPR，图形的视角可以非常形象地描绘特异度和灵敏度的相对权衡。

用一条穿过左下角到右上角的对角线将图形空间平分为两个片区，其中，位于左上片区的点表示分类结果较好（相对于随机来说），反之，另外片区的点则表示分类结果较差。如果 TPR 和 FPR 的值分别近似于 1 和 0，ROC 曲线越接近(0,1)时，表示预测效果越精确。但对不同分类器的 ROC 曲线进行比较时，多条线交织在一起，除非预测效果差距十分悬殊的情况，否则并不能直观看出分类效果更好的模型是哪个，这时需要计算 AUC 值[32]来进行比较。

AUC 是 ROC 曲线下面的面积，值越大代表分类器效果更好。AUC 表达的是一个概率值，他表示的是，当你选择一个正样本时，应用当前的分类器计算得到的分数，将这个样本排在负样本前面的概率。所以，我们可以认为，当 AUC 的值越大，当前的分类器可以得到更优的分类结果。

三、加权误判率

我们很容易构造一个高精确率或高召回率的分类器，但是很难保证两者同时成立，如果追求高的召回率，精确率可能会很低。但如果追求高的精确率，那么召回率就会很低。因此构建一个同时使两者很大的分类器是具有挑战性的。

由于没有识别出潜在的阿尔兹海默症患者会给患者带来更高的风险，因此在使用分类器进行判别时，我们希望假阴的误判代价要高于假阳，即我们希望可以得到灵敏度更高的模型，对于特异度则可以适当放宽些。基于此，对测试集定义如下加权误判

[29] Receiver operating characteristic curve, ROC
[30] False positive rate, FPR
[31] True postive rate, TPR
[32] Area under curve, AUC

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

率：

$$l(y,\hat{y})=\frac{1}{n}\sum_{i=1}^{n}w_0I(y_i=1,\hat{y}_i=0)+w_1I(y_i=0,\hat{y}_i=1) \qquad (2\text{-}6)$$

其中，w_0和w_1是人为定义的假阴和假阳代价的权重，并且满足$w_0+w_1=1$。例如，我们可以选择$w_0{:}\,w_1=2$，即表示患阿尔兹海默症但被判别为没患病的代价是没患病但被判别为患病的两倍。

在建模得到预测概率后，通过修改从 0 到 1 的阈值可以得到不同的分类结果，给定假阴错判代价与假阳错判代价的权重比值[33]，可以计算得到不同阈值下的加权误判率。我们选择使加权误判率最小时的阈值作为最终的分类准则，当模型预测得到的患病概率大于这个阈值时，则判别为患病，反之同理。

[33] 后简称为代价权重比值。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

第三章　阿尔兹海默症诊断实证研究

本节将利用第一章中介绍的机器学习方法对预处理后的阿尔兹海默症数据集进行实证研究，总共可以分为四个部分。

第一部分，通过研究不同代价权重比值与模型准确率等指标的关系选择出合适的代价权重比值，以此来计算加权误判率，从而影响分类结果的阈值，降低在进行预测时将患者诊断为正常的误判率。

第二部分，对缺失数据分别使用正则化迭代 PCA 插补法和随机森林插补法进行插补，分别得到两个完整的数据集。

第三部分，进行建模。建模共分为四个部分。第一，对两种插补法得到的数据集依次建立 Logistic 回归模型，利用向前选择法，找出对阿尔兹海默症诊断解释力最强的变量，再使用这些重要变量再次建立 Logistic 回归模型，分别简记为 impPCA_LR、impRF_LR。第二，对两种插补法插补完的两个数据集分别建立 SVM 模型，分别简记为 impRF_SVM、impRF_SVM。第三，将插补好的两个数据集分别建立随机森林模型，记为 impPCA_RF、impRF_RF。第四，利用 SAEM 法对缺失数据进行建模，首先通过研究不同参数值与模型收敛速度的关系，选择收敛速度最快的参数，然后一次性完成数据的插补和模型的建立，得到的模型记为 SAEM。

第四部分，模型结果对比。为减小偶然性带来的建模结果影响，本文将第二部分和第三部分中的插补和建模过程重复 10 次，用 10 次建模得到的平均准确率、精确率等指标进行模型间的比较。然后给出模型筛选出的与阿尔兹海默症最为相关的重要变量，并进行说明解释。

第一节　建模过程与结果

一、代价权重比值的确定

在第二章第四节中，我们提出了加权误判率这一指标。在使用模型计算出预测概率之后，生成 0 到 1 的阈值，将预测概率与阈值依次进行比较，获得不同阈值下的分类结果。当模型预测得到的患病概率大于这个阈值时，则判别为患病，反之正常。最终每个阈值都可以计算出一个对应的加权误判率，选择能使得加权误判率最小的那个阈值作为最终分类的阈值。因为我们希望模型将阿兹海默症患者诊断为正常人的错判数越少越好，这一阈值代表着对分类结果的人为修正，能够减少我们更不希望发生的错判数。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

由于选择不同的代价权重比值会计算得到不同的判别阈值，进而使得分类结果不同，最终得到的模型准确度、灵敏度、特异度等结果也会不同。因此首先需要研究每个模型的准确度等指标与代价权重比值的关系。为了保证建模后结果的可比性，我们需要对所有模型统一权重，找出每个模型结果都比较好的代价权重比值。由于患者被误诊成健康带来的风险更大，因此在选择代价权重比值时，应保证准确率较高，且特异度在可以接受的水平的同时，灵敏度越高越好。

下面图 3-1、图 3-2、图 3-3 分别展示了代价权重比值$w_0:w_1$从 1 取到 10 时，正则迭代 PCA 插补法 Logistic 回归模型（impPCA_LR）、正则化迭代 PCA 支持向量机模型（impPCA_SVM）、正则化迭代 PCA 插补法随机森林模型（impPCA_RF）、随机森林插补法 Logistic 回归模型（impRF_LR）、随机森林插补法支持向量机模型（impRF_SVM）、随机森林插补法随机森林模型（impPCA_RF）、SAEM 模型的准确率、灵敏度、特异度与不同代价权重比值的关系。

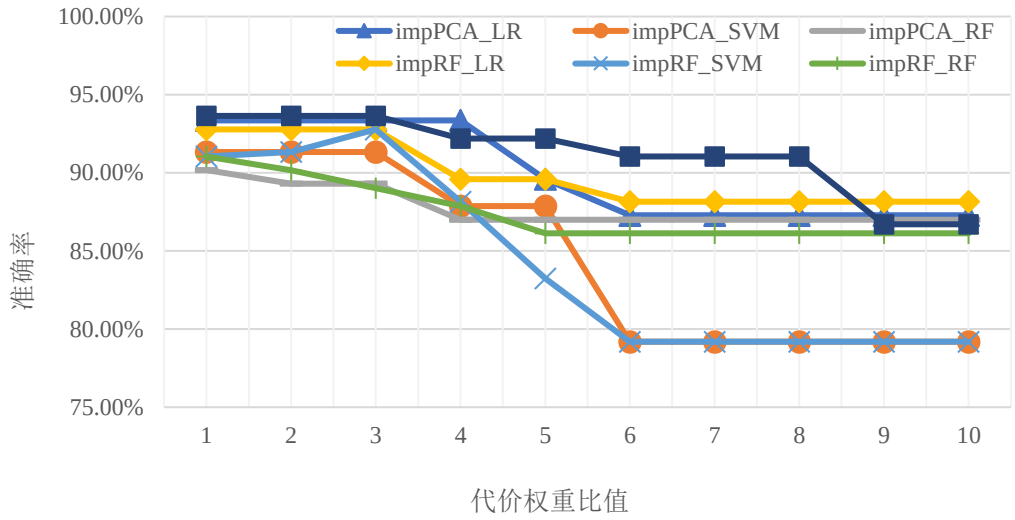

图 3-1 代价权重比值与准确率的关系

从图 3-1 可以看出，随着代价权重比值逐渐增加，7 个模型的准确度基本呈现平稳后下降最后又趋于平稳的趋势。$w_0:w_1$在 1 到 3 之间时，模型的准确度在 89.02%到 93.64%之间。$w_0:w_1$取 4 时，模型的准确度有所下降，在 87.86%到 93.35%之间。在$w_0:w_1$取 5 时，impRF_SVM 的准确度下降到 83.24%。在$w_0:w_1$在 6 到 10 之间时，impPCA_SVM 和 impRF_SVM 下降到了 79%左右。因此从准确度来看，$w_0:w_1$的可选择范围在 1 到 5 之间。

从图 3-2 可以看出，代价权重比值越高，7 个模型的灵敏度越高。$w_0:w_1$取 1 时，SAEM 和 impPCA_LR 的灵敏度在 96.5%以上，而其他模型的灵敏度在 93.01%到 94.32%之间。$w_0:w_1$取 2、3 时，模型的灵敏度在 94.32%到 97.38%之间。$w_0:w_1$取 4、5 时模型的灵敏度在 96.51%到 99.13%之间。$w_0:w_1$在 98.69%到 99.56%之间。我们希望模型最低的灵敏度能够在 95%以上，因此从灵敏度来看，$w_0:w_1$的可选择范围在 4 到 10 之间。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

从图 3-3 可以看出，随着代价权重比值的升高，7 个模型的特异度逐渐降低，且不同模型的特异度差别增大。$w_0:w_1$为 1 时，模型的特异度在 84.62%到 89.74%之间。$w_0:w_1$取 2、3 时，impPCA_RF 和 impRF_RF 的特异度下降到 75%左右。$w_0:w_1$为 4 时，模型的特异度在 64.10%到 87.18%之间。$w_0:w_1$大于等于 5 时，模型的特异度最低仅为 39.32%，将正常人预测为患者的错判率过高。虽然$w_0:w_1$取 4 时，有两个模型的特异度在 65%左右，但是其他模型均能保证在 70%以上，因此从特异度来看，$w_0:w_1$的可选择范围在 1 到 4 之间。

综上所述，代价权重比值取 4 时，7 个模型的准确度、灵敏度、特异度都在比较理想的水平。

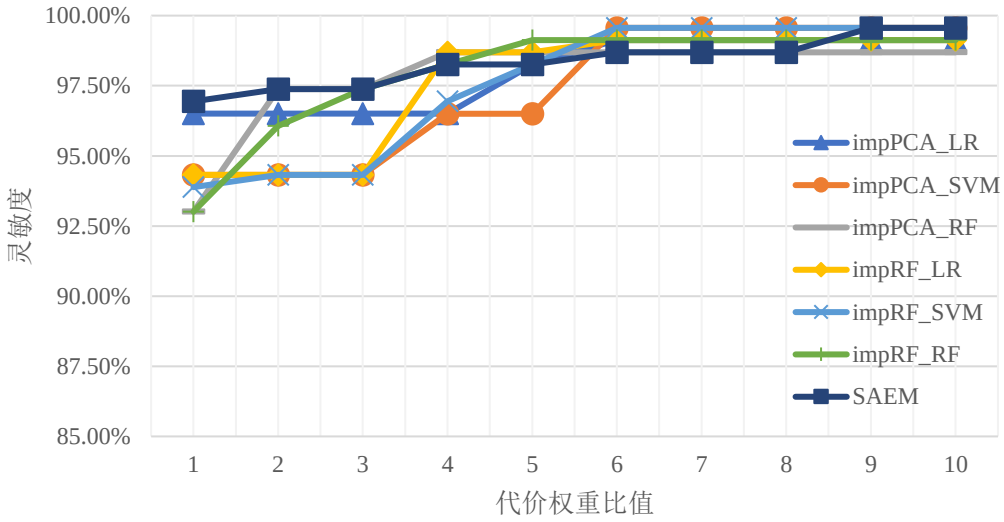

图 3-2 代价权重比值与灵敏度的关系

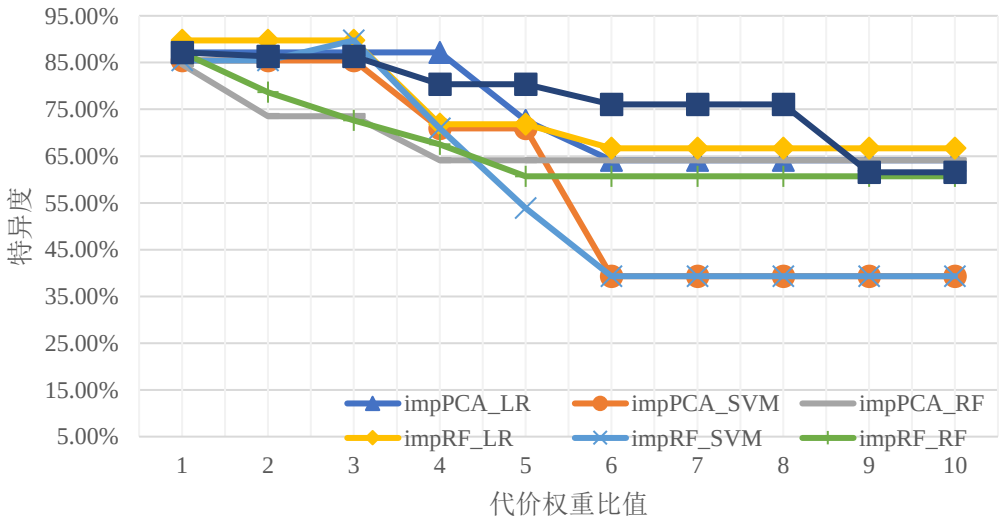

图 3-3 代价权重比值与特异度的关系

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

二、插补法 Logistic 回归的建模过程与结果

首先在 R 中分别使用 missMDA 包实现正则化迭代 PCA 算法对缺失数据集进行插补，用 missForest 包实现随机森林插补法对数据集进行插补。两种插补方法插补完成后，可以得到两个完整的数据集。分别对每个数据集建立 Logistic 回归模型，再利用向前选择法进行特征选择，找出解释性更强的变量，再利用选择出的变量建立最终的 Logistic 回归模型。

向前选择法的步骤是，首先遍历所有特征，然后从中选择重要程度最大的特征引入模型。然后每次再把特征重要性次高的候选特征逐个引入模型。直到新特征的加入不再使得模型的拟合效果更好为止。衡量特征的重要程度的方法包括 AUC、准确率、AIC 和 BIC 等。

最后利用向前选择法根据 BIC 准则筛选得到的变量建立最终的预测模型。表 3-1、表 3-2[34]分别展示了正则化迭代 PCA 插补法 Logistic 回归模型、随机森林插补法 Logistic 回归模型估计的参数和残差以及 p 值，这些变量的水平与阿尔兹海默症的病情有着极强的相关性。

表 3-1 正则化迭代 PCA 插补法 Logistic 回归模型参数估计结果

Variables	Estimate	Std. Error	z value	Pr(>|z|)
(Intercept)	4.631	0.4269	10.848	< 2e-16***
LDELTOTAL	-5.99	0.4973	-12.045	< 2e-16***
FAQTOTAL	2.4379	0.5365	4.544	5.52E-06***
PTEDUCAT	-1.1251	0.1731	6.498	8.13E-11***
ST18SV	-0.4187	0.166	-2.522	0.01166*
GDTOTAL	0.6108	0.1534	3.981	6.86E-05***
ST93CV	0.514	0.1529	3.362	0.000773***
ST110TS	-0.4638	0.1377	-3.369	0.000754***
ADAS_TOTAL	1.0242	0.2741	3.737	0.000186***
ST49TA	0.4277	0.1547	2.764	0.005703**

从表中可以得出以下信息：

1、逻辑延时回忆能力得分（LDELTOTAL）的水平值是受试者听一个故事，在故事结束后能够回想起的情节数，能够体现受试者的延时记忆力。这一分数越高，表示能够回想起的情节更多，也就是说明延时记忆力更好。老年痴呆评估量表得分（ADAS_TOTAL）也是通过回忆、辨认单词来衡量受试者记忆和认知能力。从符号可以看出，记忆力和认知能力越好，被诊断为阿尔兹海默症的可能性就越低，符合阿兹海默症与记忆力和认知能力退化强相关的典型特征。

2、日常生活功能性评估得分（FAQTOTAL）评估了受试者从事日常活动的困难

[34] 表中结果为 10 次建模中，BIC 准则最小的一次。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

程度，如购物、做饭、乘坐公共交通工具、培养技巧类游戏的爱好等。从符号可以看出，说明独立完成日常活动的能力越差，患阿尔兹海默症的可能性越高。

3、受教育年限（PTEDUCAT）越高，患阿尔兹海默症的风险越低。

4、老年抑郁量表总分（GDTOTAL）衡量了老年人的抑郁程度。兴趣减退、精神空虚、感到无助、自我否定的情绪都和阿尔兹海默症高度相关。

5、退休（PTNOTRT）人群患阿尔兹海默症的风险高于未退休人群，说明从事劳动能够降低罹患痴呆的风险。

6、阿尔兹海默症与以下临床特征高度相关，左侧小脑体积（ST18SV）、右中央前皮质厚度标准差（ST110TS）、右颞极平均皮质厚度（ST119TA）更小的数值，右扣带肌体积（ST93CV）、左后心皮层厚度平均值（ST49TA）、左枕骨外侧皮质平均厚度（ST35TA）更大的数值预示着患阿尔兹海默症的可能性更高。

表 3-2 随机森林插补法 Logistic 回归模型参数估计结果

Variables	Estimate	Std. Error	z value	Pr(>|z|)
(Intercept)	8.0945	0.9205	8.793	< 2e-16***
LDELTOTAL	-6.7062	0.6052	-11.081	< 2e-16***
FAQTOTAL	3.2767	0.7524	4.355	1.33E-05***
PTEDUCAT	-1.1151	0.1835	6.076	1.24E-09***
ST35TA	0.912	0.1898	4.806	1.54E-06***
ADAS_TOTAL	1.4237	0.3038	4.686	2.78E-06***
GDTOTAL	0.6918	0.1537	4.5	6.78E-06***
ST110TS	-0.6543	0.1555	-4.209	2.57E-05***
ST93CV	0.6445	0.1695	3.802	0.000144***
PTNOTRT	-1.183	0.3487	-3.393	0.000692***
ST119TA	-0.62	0.1875	-3.306	0.000946***
PXPERIPH	-1.4466	0.5498	-2.631	0.008504**

图 3-4、图 3-5 分别展示了正则化迭代 PCA 插补法、随机森林插补法分别与 Logistic 回归组合建模 10 次绘制出的 ROC 曲线，可以看出三个模型的 ROC 曲线均接近左上角，说明了预测效果良好。

表 3-3 插补法 Logistic 回归模型的预测效果

准则	impPCA_LR	impRF_LR
AUC	97.59%	97.55%
accuracy	91.47%	90.46%
precision	90.17%	88.63%
sensitivity	98.39%	98.73%
specificity	76.00%	72.45%
WERR	2.36%	2.43%

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

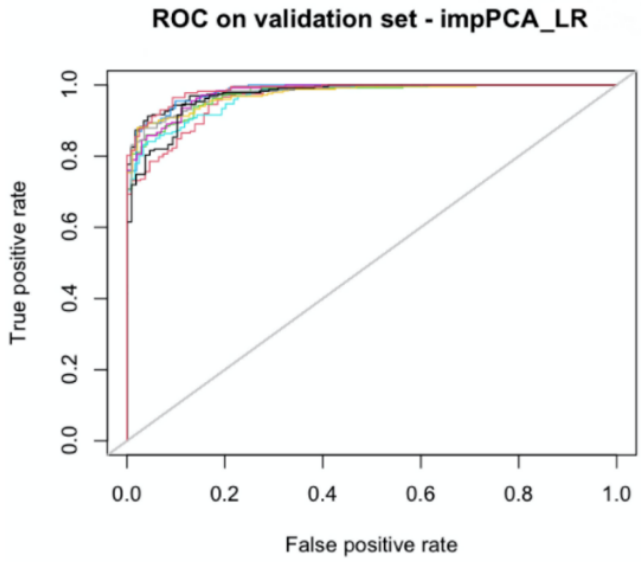

图 3-4 正则化迭代 PCA 插补法 Logistic 回归模型的 ROC 曲线

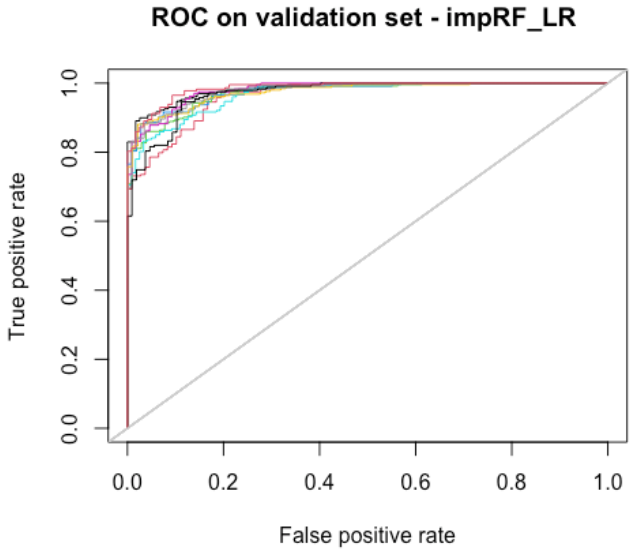

图 3-5 随机森林插补法 Logistic 回归模型的 ROC 曲线

为减少随机因素带来的影响，综合评估模型的效果，文章对上述过程重复了 10 次。根据这 10 次建模结果计算平均值后计算得到的评价指标结果如表 3-3 所示。可以看出，两个模型的 AUC 均在 97%以上，准确率均在 90%以上、灵敏度均在 98%以上，表明建模整体效果良好，对于阿尔兹海默症患者的识别效果十分优良。

三、插补法 SVM 的建模过程与结果

下面利用正则化迭代 PCA 插补法和随机森林插补法得到的完整数据集，建立 SVM 模型，通过和 k 折交叉验证法寻找最优参数。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

本文将使用 R 语言实现 SVM 模型的构建。构建 SVM 模型时影响其分类效果的参数包括核函数，不同的核函数表示着向高维空间的不同映射方式。常用的有线性核、多项式核、径向基核和 sigmoid 核函数。此外，可以通过调节参数 gamma 值来改变模型的复杂度，解决欠拟合或者过度拟合等问题。为了使模型泛化能力增强，我们还可以通过调节参数惩罚系数 C 来改变松弛因子的大小，松弛因子过大或过小会出现过拟合或者欠拟合的问题，因此惩罚系数 C 的值的选择直接影响到了模型的稳定性。

在运用二次规划方法来求解支持向量机时会涉及到大量的矩阵计算，本文的训练集样本量大小为 1730，那么就需要计算 1730 阶矩阵。若直接通过网格搜索法来搜索核函数、惩罚系数 C 和 gamma 的最优解，那么则需要大量的内存空间和运算时间。查阅相关资料了解到，在利用 SVM 进行分类问题时 kernel 的选择对于结果的影响最为显著。为了提升建模效率，因此在选择核函数前先考察不同核函数在默认参数或最优参数的情况下的表现。

表 3-5 不同核函数在默认参数下的表现

准则	线性核	Sigmoid	径向基核	多项式核
AUC	84.71%	84.32%	81.15%	57.46%
accuracy	86.13%	86.99%	85.84%	70.52%
precision	89.87%	88.33%	84.88%	69.78%
sensitivity	89.08%	92.58%	95.63%	97.82%
specificity	80.34%	76.07%	66.67%	17.09%
WERR	6.74%	7.56%	9.87%	23.60%

表 3-6 不同核函数在最优参数下的表现

准则	线性核	Sigmoid	径向基核	多项式核
AUC	84.71%	86.05%	84.12%	71.53%
accuracy	86.13%	88.73%	87.28%	79.19%
precision	89.87%	89.26%	87.76%	78.14%
sensitivity	89.08%	94.32%	93.89%	95.20%
specificity	80.34%	77.78%	74.36%	47.86%
WERR	6.74%	6.89%	7.90%	15.22%

表 3-5 和表 3-6 展示了随机森林插补法 SVM 模型不同核函数在默认参数和最优参数下的建模结果。从表中可知，默认参数下多项式核函数的特异度仅为 17.09%，最优参数下特异度仅为 47.86%，因此首先将其排除。径向基核函数的加权误判率在默认参数下和最优参数下，均高于线性核和 sigmoid 核，并且特异度也比这两个核函数表现更差，因此也将其排除。线性核函数的 AUC、准确率、精确率与 sigmoid 核函数都比较相似，然而 sigmoid 的灵敏度在最优参数下可以达到 94%以上，高于线性核函数。在本文所研究的阿尔兹海默症诊断中，我们更关注对于患病者的识别度，因此应选择灵敏度更高的模型。因此最终，在线性核函数和 sigmoid 核函数中，我们选择了灵敏度相对较好的 sigmoid 核函数。对正则化迭代 PCA 插补法 SVM 模型也进行上述分析，结果与上述结果相似，故不再赘述，最终也选择 sigmoid 核函数。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

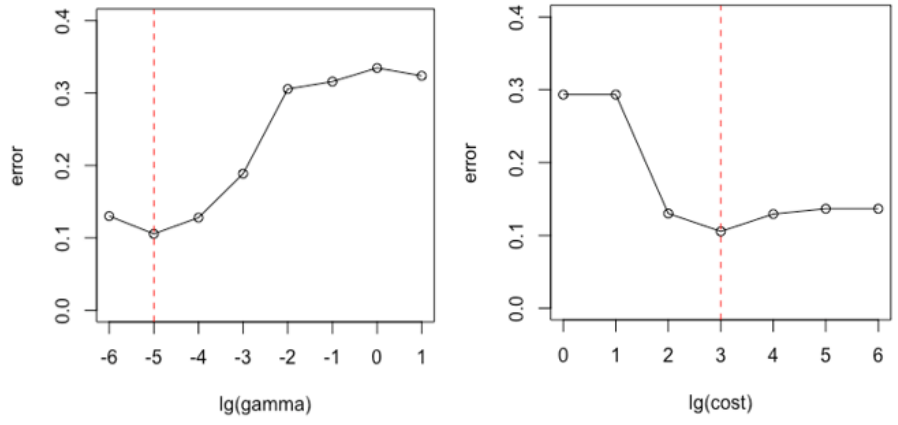

图 3-6 C 和 gamma 对错误率的影响

在进行网格搜索之前本文先确定了单个参数的搜索范围，这一目的是在于缩小整体搜索范围加快搜索速度减少内存消耗，然后再根据确定出的参数范围构建参数组合再进行寻参。图 3-6 表现了在参数选择过程中，基于随机森林插补法 SVM 模型的惩罚系数 C、gamma 与错误率（1-accuracy）的关系。

两个模型的 ROC 曲线如图 3-7、图 3-8 所示。可以看出图线十分接近左上角，表明预测效果良好。正则化迭代 PCA 插补法 SVM 模型 10 次重复建模的平均 AUC 值为 95.66%，准确率为 89.02%，精确率为 88.56%，灵敏度为 96.54%，特异度为 72.65%。随机森林插补法 SVM 模型 10 次重复建模的平均 AUC 值为 95.52%，准确率为 89.15%，精确率为 89.29%，灵敏度为 95.64%，特异度为 75.00%。

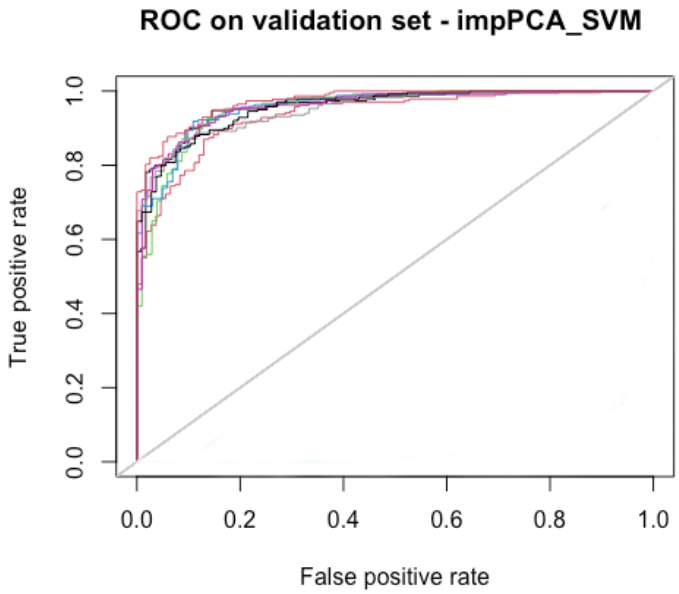

图 3-7 正则化迭代 PCA 插补法支持向量机模型的 ROC 曲线

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

表 3-7 插补法 SVM 模型的预测效果

准则	impPCA_SVM	impRF_SVM
AUC	95.66%	95.52%
accuracy	89.02%	89.15%
precision	88.56%	89.29%
sensitivity	96.54%	95.64%
specificity	72.65%	75.00%
WERR	3.62%	3.95%

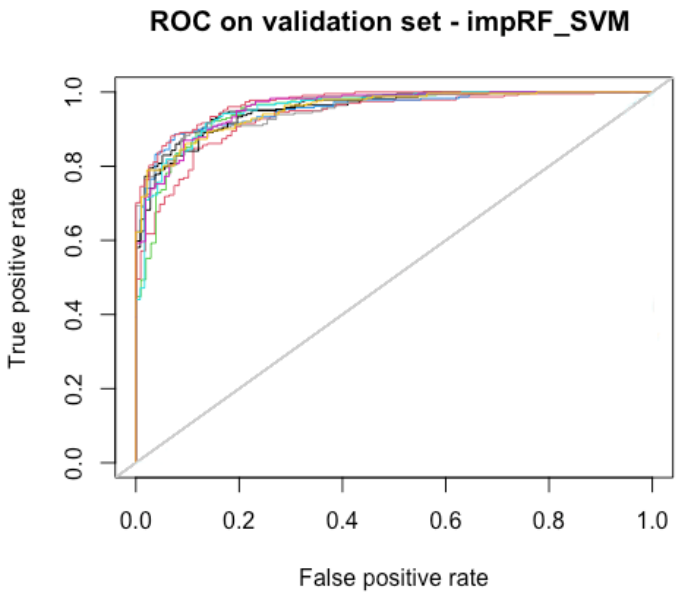

图 3-8 随机森林插补法支持向量机模型的 ROC 曲线

四、插补法随机森林的建模过程与结果

在建立随机森林模型之前，需要先通过迭代正则化 PCA 插补法和随机森林插补法来得到完整的数据集，之后再通过网格搜索法和交叉验证法来确定随机森林模型函数的最优解。

本文通过利用 python 中的 sklearn 包来建立随机森林模型，主要参数如下。n_estimators 表示构造的模型中有多少颗决策树，即弱学习器的个数。其值影响到模型的拟合程度，若其过小那么会出现欠拟合问题，但是如果该值过大会增加计算时间且该值的增大对模型的提升有限。max_depth 表示构造的每个树的节点与根节点的最大的距离。若数据集样本特征多那么其值一般设置在 10-100 之间，在数据样本特征少的情况下可以选择默认值。min_samples_leaf 和 min_samples_split 两个参数分别表示叶节点所包含的样本数的最小值和节点再划分的样本最小值。在样本量不大时可以选择默认值，如果样本量特别大，则适当增大这个值。criterion 是节点分裂时计算特征信息的准则，默认是基尼系数，也可选信息增益。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

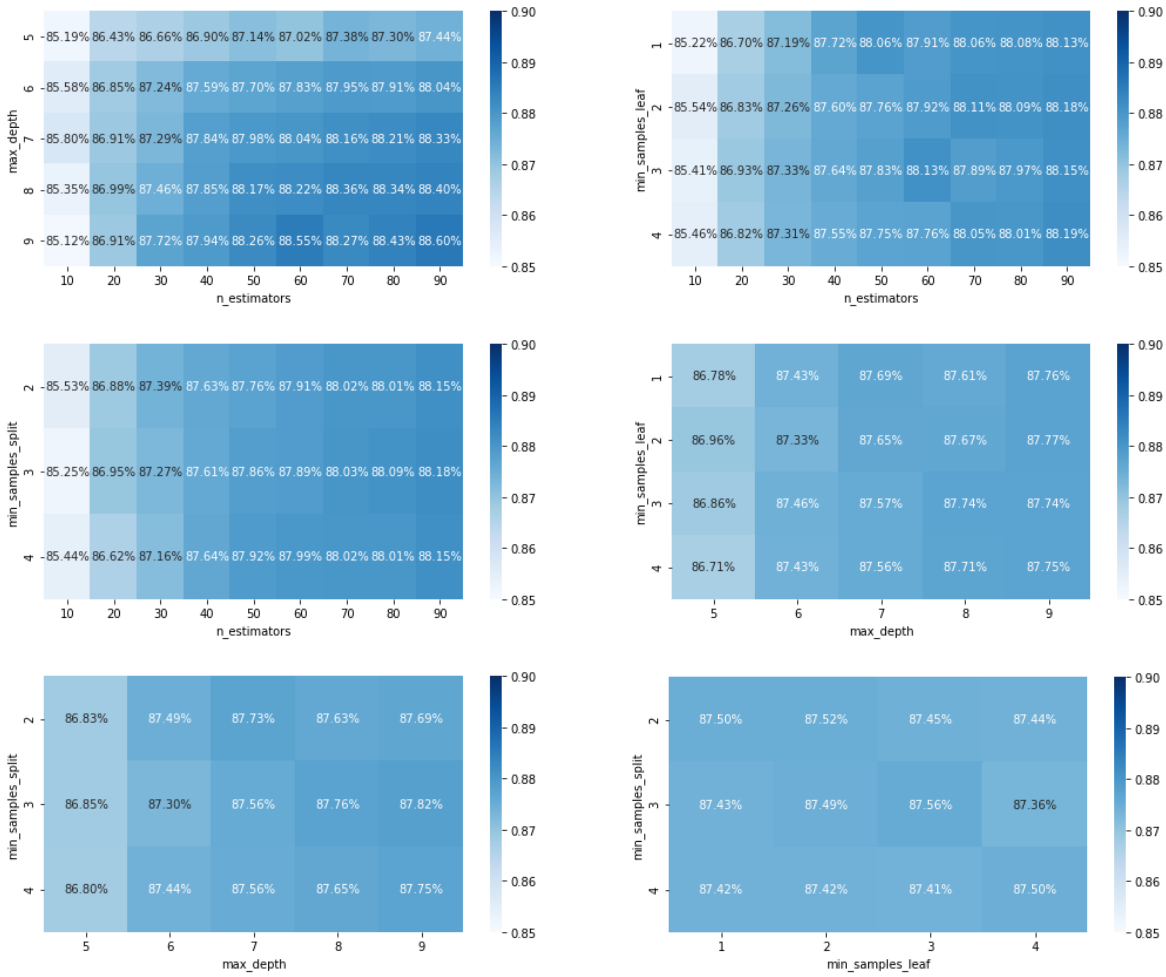

图 3-9 随机森林参数对准确率的影响关系

为提升寻参效率，查阅资料可知，n_estimators 对模型的结果影响最大，因此首先缩小其搜索范围，以减少调参时间。对所有参数组合依次进行建模，最后确定寻找出效果最高的参数组合，图 3-9 展示了随机森林插补法随机森林模型再进行调参过程中，模型参数值与准确率之间的关系。数据显示 criterion 参数对于模型结果影响较小，因此图中只展示了其他四个参数与准确率的关系。图中颜色的深度表示了其参数影响准确率程度的高低，颜色越深表示准确率越高。从图 3-9 的第 1 至 3 张图中可以看出，n_estimators 越大，准确率越高，验证了其为对模型影响最明显的参数。

表 3-9 插补法随机森林模型的预测效果

准则	impPCA_RF	impRF_RF
AUC	96.06%	95.74%
accuracy	89.39%	89.13%
precision	88.01%	88.05%
sensitivity	98.01%	97.33%
specificity	70.07%	71.33%
WERR	2.94%	3.27%

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

重复 10 次建模过程，每次选择效果最好的参数组合预测正则化迭代 PCA 插补法随机森林模型和随机森林插补法随机森林模型。最终得到两个模型预测结果的平均 AUC 均在 95%以上，准确率、精确率均在 88%以上，灵敏度在 97%以上。图 3-10、图 3-11 展示了两种插补法随机森林模型的 ROC 曲线图，可以看出图线接近左上角，预测效果良好。

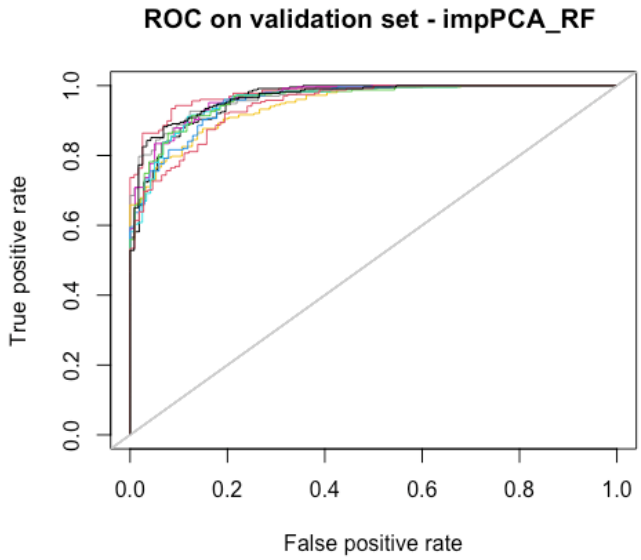

图 3-10 正则化迭代 PCA 插补法随机森林模型的 ROC 曲线

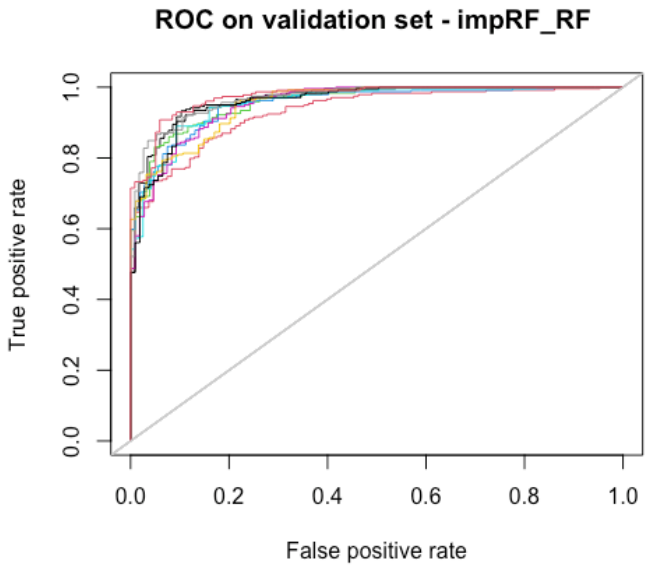

图 3-11 随机森林插补法随机森林模型的 ROC 曲线

为研究模型引入的众多变量中哪些变量对于识别阿尔兹海默症患者更加有效，可以使用随机森林进行特征重要性评估。其思想与具体计算公式在第一章第二节中已介绍。表 3-10、表 3-11 展示了插补法随机森林模型重要性分数在前 15 的重要变量排

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

序。此次建模选择出的重要变量与 Logistic 回归利用向前选择法筛选出的重要变量都选择出了 LDELTOTAL、FAQTOTAL、ADAS_TOTAL、GDTOTAL。然而也筛选出了不同的变量，具体有衡量记忆能力的指标如逻辑瞬时记忆能力得分（LIMMTOTAL）、Crane 实验室神经心理学记忆得分（ADNI_MEM），衡量生活能力的指标 Crane 实验室神经心理学执行功能得分（ADNI_EF），衡量认知能力的指标如听觉语言学习测试

表 3-10 正则化迭代 PCA 插补法随机森林模型的变量重要性

重要性排序	变量名	重要性分数
1	LDELTOTAL	0.12340021
2	LIMMTOTAL	0.06199891
3	ADNI_MEM	0.03751122
4	FAQTOTAL	0.03390079
5	ADAS_TOTAL	0.03298066
6	MMSCORE	0.02786491
7	AVDELTOT	0.01878434
8	AVTOT6	0.01743990
9	ST24TA	0.01719901
10	ST83TA	0.01262729
11	ADNI_EF	0.01070945
12	GDTOTAL	0.00989936
13	AVDELTOT	0.00966388
14	ST29SV	0.00909530
15	PTAU	0.00869713

表 3-11 随机森林插补法随机森林模型的变量重要性

重要性排序	变量名	重要性分数
1	LDELTOTAL	0.08045107
2	ADAS_TOTAL	0.06112680
3	LIMMTOTAL	0.05956224
4	FAQTOTAL	0.05910744
5	ADNI_MEM	0.04854658
6	MMSCORE	0.02386041
7	AVTOT3	0.01605616
8	AVTOT4	0.01580416
9	HCI	0.01557362
10	ST136HS	0.01458659
11	AVTOT5	0.01333645
12	ST24TA	0.01216941
13	TAU	0.01084201
14	ST83TA	0.00935532
15	ABETA	0.00861057

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

认知得分（AVDELTOT）、简易智力状态检查量表得分（MMSCORE），以及临床生物指标 Aβ蛋白（ABETA）、Tau 蛋白（TAU）、代谢趋缓指数（HCI）、右内嗅皮层皮质厚度平均值（ST83TA）、左内嗅皮层皮质厚度平均值（ST24TA）、左海马体积(WM 分割)（ST29SV）等。

五、SAEM 法的建模过程与结果

在第一章关于 SAEM 的理论介绍中，我们提到了 SAEM 法的第二步，即进行随机逼近的时候，对于非递增序列(γ_k)的选择非常重要，这是 SAEM 算法能够收敛到最大似然的保障。为了快速收敛到最大似然估计的一个邻域，我们参考 Wei Jiang、Julie Josse 等人在提出 SAEM 算法时所使用的(γ_k)的设置。即在前k_1次迭代中选择$\gamma_k = 1$，从k_1次迭代开始，设置$\gamma_k = (k - k_1)^{-\tau}$，以确保 SAEM 几乎肯定收敛。

为了研究步长序列(γ_k)对于收敛速度的影响，我们设置最大迭代次数为 500，令$k_1 = 50$，并在接下来的 450 次迭代中，依次使用$\tau = (0.6,\ 0.8,\ 1)$来观察收敛情况。

图 3-13 展示了τ分别为 0.6、0.8、1 时，使用本文所研究的数据中任意选择出的一个变量的估计参数随迭代次数的增大的收敛情况。可以看出(γ_k)的三个序列都收敛到相同的解，但对于较大的τ，SAEM 算法收敛更快，波动更小，因此在下面的建模过程中，我们使用$\tau = 1$。

SAEM 法能够直接对缺失数据进行插补和建模。对预处理过后的数据在 R 中应用 SAEM 算法，得到预测概率后绘制 ROC 曲线如图 3-14 所示。根据混淆矩阵计算得到平均 AUC 值为 98.05%，准确率为 91.62%，精确率为 90.00%，灵敏度为 98.78%，特异度为 76.07%，预测效果良好。

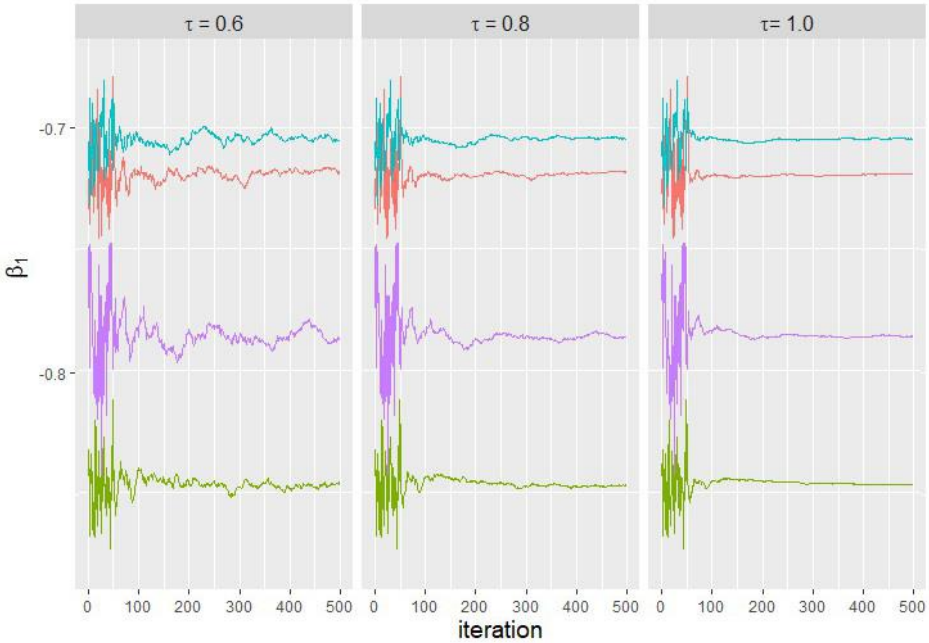

图 3-12 τ的取值对 SAEM 参数收敛的影响

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

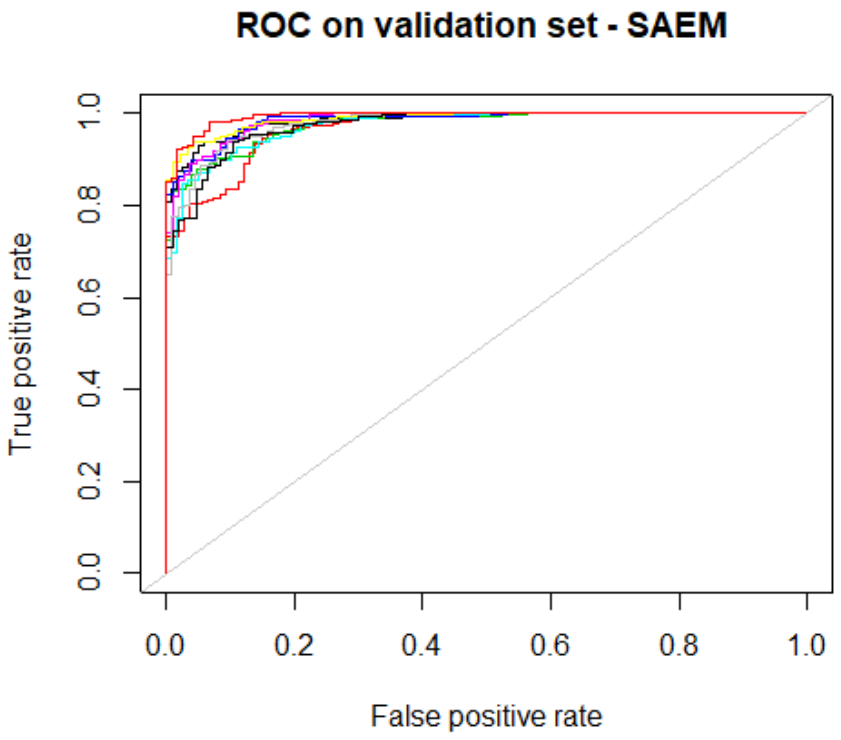

图 3-13 SAEM 的 ROC 曲线

第二节　模型结果对比与分析

一、预测精度对比

在上一节中我们利用了正则迭代 PCA 插补法 Logistic 回归模型（impPCA_LR）、正则化迭代 PCA 支持向量机模型（impPCA_SVM）、正则化迭代 PCA 插补法随机森林模型（impPCA_RF）、随机森林插补法 Logistic 回归模型（impRF_LR）、随机森林插补法支持向量机模型（impRF_SVM）、随机森林插补法随机森林模型（impPCA_RF）、SAEM 模型共 7 个模型实现了对阿尔兹海默症病情诊断预测。为了减小随机性的影响，所有的建模过程均被重复了 10 次。绘制 7 个模型的 AUC 值、准确率、精确率、灵敏度、特异度、加权误判率的箱线图如图 3-14 至图 3-19 所示。

从图 3-14 中可以看出，7 个模型的 AUC 值都比较高，中位数均在 95%以上。其中 SAEM 模型表现最好，中位数为 98.12%，最好一次预测 AUC 值达到了 99.33%。impPCA_LR、impRF_LR 的 AUC 表现优异，仅次于 SAEM 模型，其 AUC 中位数均在 97.5%以上。impPCA_SVM 和 impRF_SVM、impPCA_RF 和 impRF_RF 的分布比较接近，AUC 值的中位数几乎持平，在 96.5%左右，是 7 个模型中表现相对较差的四个模型。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

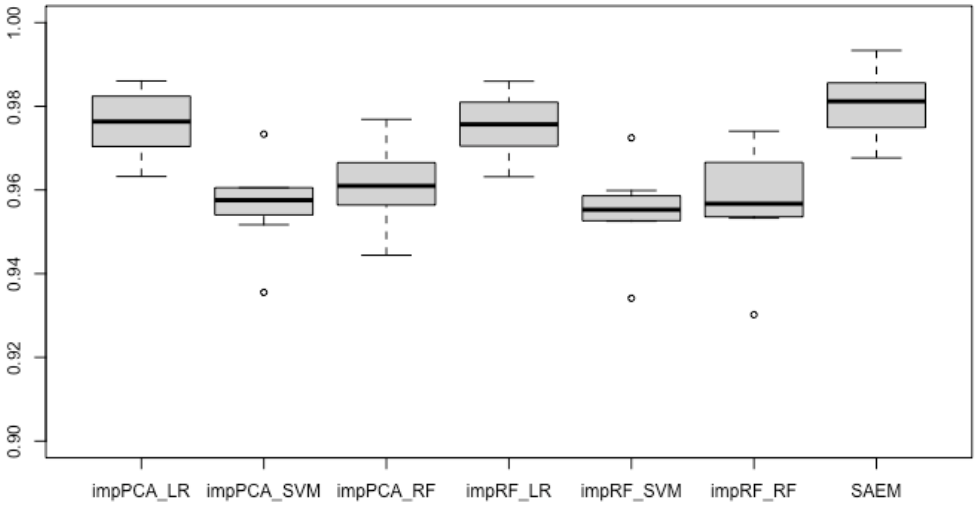

图 3-14 模型 AUC 值比较

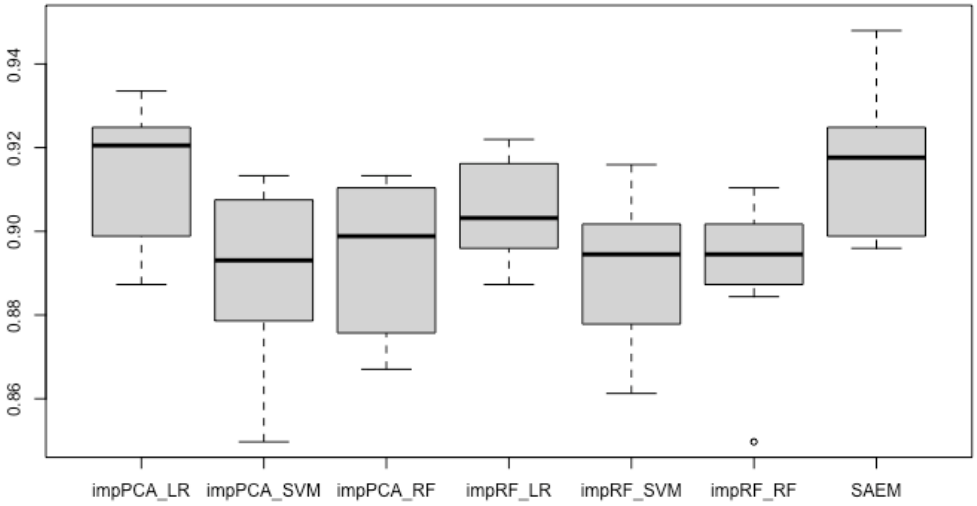

图 3-15 模型准确率比较

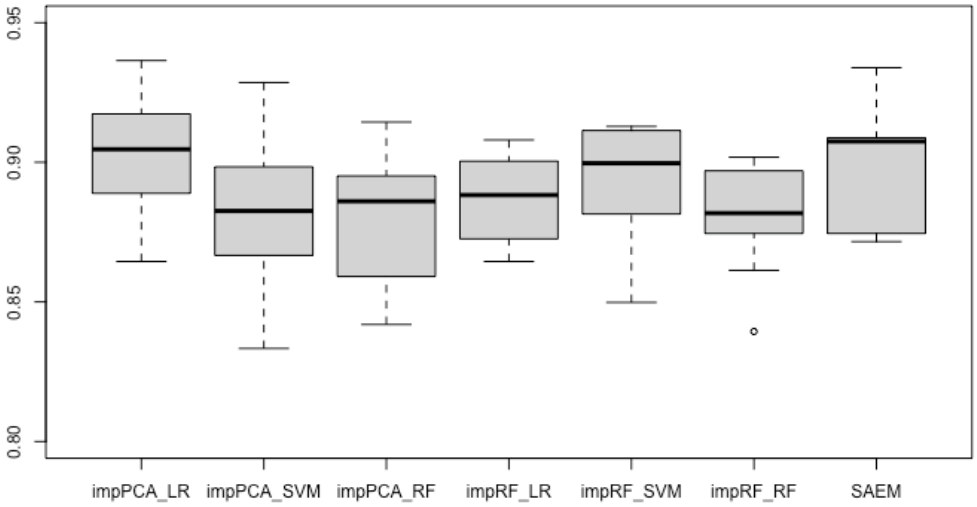

图 3-16 模型精确率比较

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

图 3-15 对比了模型的准确率情况。impPCA_LR 模型的准确率中位数在 7 个模型中最高，为 92.05%。其次为 SAEM 模型，中位数为 91.18%，其最好一次预测的准确率是 7 个模型在 70 次建模中表现最好的，达到了 94.80%。其他模型的表现从好到差排序依次为 impRF_LR、impRF_RF、impPCA_RF、impRF_SVM、impPCA_SVM。图 3-16 中展示了精确度的结果，其表现排序与准确率较为接近，不再详述。

灵敏度是本文研究中最为关注的评价指标。对比图 3-17 中多个模型的灵敏度值可以看出 SAEM 模型整体表现最好，灵敏度中位数为 98.97%，并且波动范围最小。impPCA_LR 和 impRF_LR 的结果比较接近，在 7 个模型中灵敏度仅次于 SAEM 模型，中位数均在 98.5%以上。两者相比，impRF_LR 的灵敏度最小值比 impPCA_LR 更小，且整体波动更小。impPCA_RF 灵敏度表现排在第三位，中位数为 97.94%。

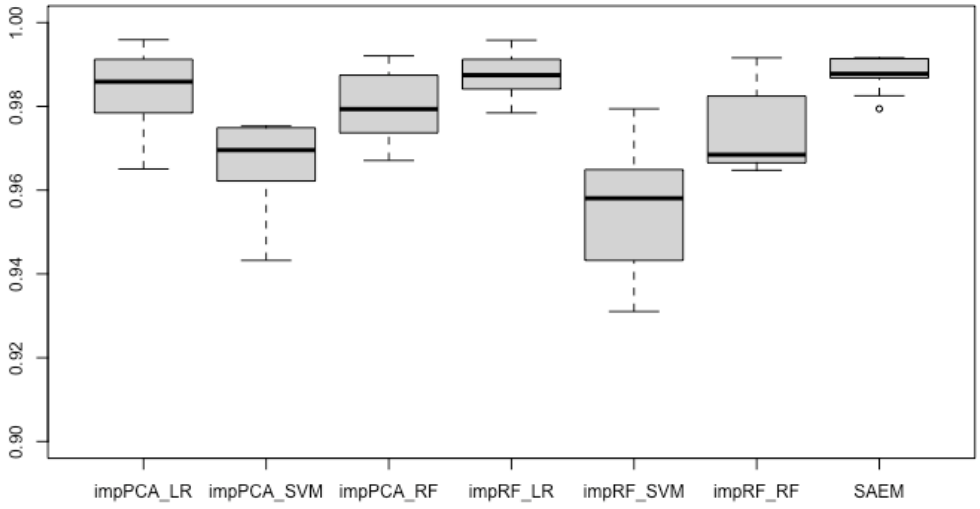

图 3-17 模型灵敏度比较

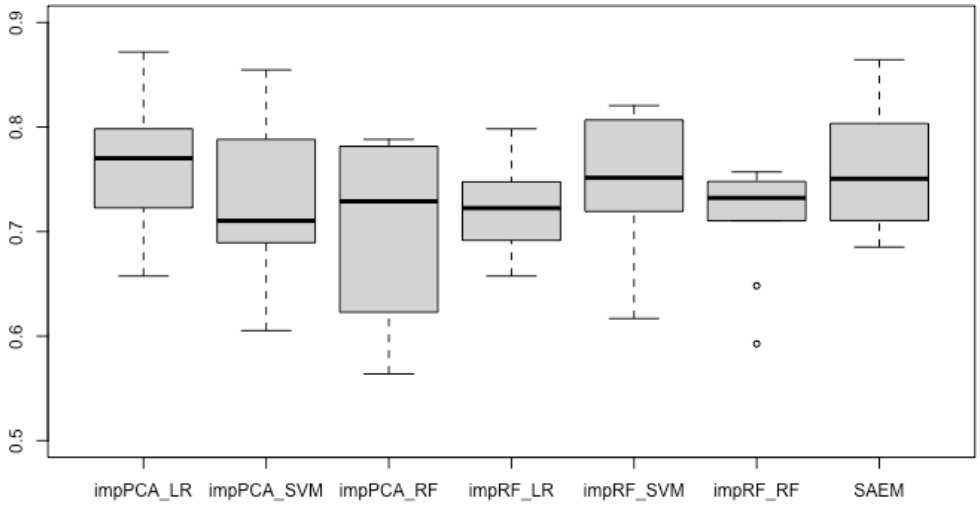

图 3-18 模型特异度比较

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

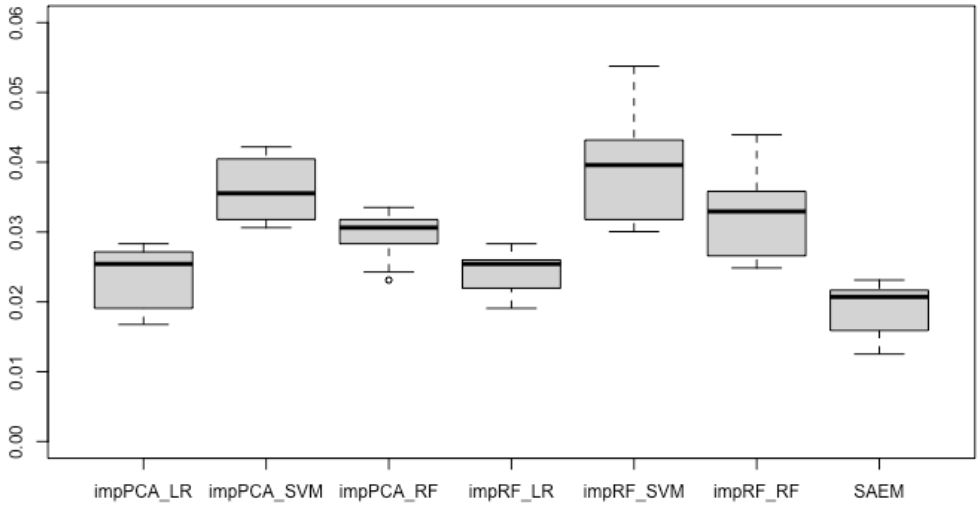

图 3-19 模型加权错误率比较

impRF_RF 的灵敏度分布比较右偏，50%的灵敏度处在 96.65%到 98.03%之间，其中位数为 96.85%，与 impPCA_SVM 的中位数水平比较接近。impRF_SVM 表现最差，其灵敏度中位数为 95.81%。

图 3-18 展示了模型的特异度比较结果。由于我们设置了假阴的代价权重高于假阳，牺牲了一部分特异度来换取更高的灵敏度，因此 7 个模型的特异度均都没有超过 90%，中位数均在 70%到 80%之间。其中，impPCA_LR 的特异度表现最好，中位数为 77.02%。impPCA_RF 的整体表现最差，最差的一次预测特异度值仅为 56.38%。尽管模型整体的特异度水平值不够优异，但是除 impPCA_RF 之外的 6 个模型的特异度依然在可以接受的水平范围内。

最后比较模型的加权错误率，从图 3-19 中可以看出 SAEM 模型是加权误判代价最低的模型，且 10 次建模结果的波动最小。impPCA_LR 和 impRF_LR 的中位数比较接近，略低于 SAEM 模型。其他模型在加权误判代价上的表现从好到差排序依次为 impPCA_RF、impRF_RF、impPCA_SVM、impRF_SVM。

将上述 7 个模型的 10 次建模结果进行平均，汇总如下。在每个评价准则中，表现最好的模型已用粗体标识出。

在模型效果比较时，应该综合考虑各项评估准则。在阿尔兹海默症病情诊断这一分类任务中，一个人患病而模型判别为没患病的代价是远大于将没患病而诊断为患病的。因此我们更应关注灵敏度信息。通过表 3-12 可以看出，灵敏度高于 98%的模型有 impPCA_LR、impRF_LR 和 SAEM。其中，SAEM 模型是灵敏度最高的，达到了 98.78%。同时 SAEM 模型的 AUC 值、准确率、灵敏度、特异度均优于其他 6 个模型。综合以上分析，我们认为 SAEM 法是利用 ADNI 数据库基线数据对病人进行阿尔兹海默症病情诊断效果最好的模型。此外，impPCA_LR 的效果也比较好，能够在灵敏度达到 98.39%的同时特异度为 76%，并且准确度是最高的模型。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

表 3-12 不同模型的平均预测表现

模型	AUC	accuracy	precision	sensitivity	specificity	WERR
impPCA_LR	97.59%	91.47%	**90.17%**	98.39%	76.00%	2.36%
impRF_LR	97.55%	90.46%	88.63%	98.73%	72.45%	2.43%
impPCA_SVM	95.66%	89.02%	88.56%	96.54%	72.65%	3.62%
impRF_SVM	95.52%	89.15%	89.29%	95.64%	75.00%	3.95%
impPCA_RF	96.06%	89.39%	88.01%	98.01%	70.07%	2.94%
impRF_RF	95.74%	89.13%	88.05%	97.33%	71.33%	3.27%
SAEM	**98.05%**	**91.62%**	90.00%	**98.78%**	**76.07%**	**1.94%**

对比插补法 Logistic 回归、插补法支持向量机、插补法随机森林这三组模型可以看出，对数据进行插补后进行 Logistic 回归的效果要好于随机森林和 SVM，说明 Logistic 回归模型更适合本文所研究的场景。此外，随机森林的预测效果要好于 SVM。

将使用了正则化迭代 PCA 插补法的三个模型与使用了随机森林插补法的三个模型进行对比，可以看出使用了 PCA 插补法的模型的 AUC、准确度、精确度都要好于随机森林插补法。说明正则化 PCA 插补法比随机森林插补法更加适合本文所使用的数据。

对比插补法 Logistic 回归模型和同样基于 Logistic 回归的 SAEM 模型，SAEM 的准确度、AUC 值和灵敏度均优于前述模型，这说明 SAEM 法的效果更好的原因是在于对数据的插补效果更好。这是由于 SAEM 法在进行缺失值插补时所使用的条件分布将响应变量也纳入了进来，因此这个方法再进行插补时不仅利用了观测到的解释变量的信息，同时利用了响应变量的信息，而其他插补法均忽略了对响应变量信息的利用。

二、重要解释变量

阿尔兹海默症不断增长的公众威胁已经大大提升了发现和验证预后生物标志物的紧迫性。研究重要解释变量的目的一方面是为了找出最有助于识别阿尔兹海默症患者的特征，另一方面是从预防的角度来考察哪些因素的人为干预能够降低患阿尔兹海默症的风险，或是延缓病情的发展。

在上一节中，我们通过向前选择法对 impPCA_LR、impRF_LR 进行了特征选择，并且计算了 impPCA_RF、impRF_RF 的特征重要性，找出了 533 个解释变量中对于阿尔兹海默症诊断解释性最强的变量，其变量值水平的高低与痴呆进程有着很大的相关性。下面本节将综合四个模型特征筛选的信息，给出综合解释变量重要程度排序。对于 Logistic 回归模型，记录建模 10 次过程中通过 BIC 准则最小时被筛选出的变量，以及变量总共被筛选出的次数。对于随机森林模型，记录每次建模过程中变量重要性在 0.005 以上的变量，以及总共出现的次数。最后，再统计出这些变量在四个重要解

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

释变量集总共中出现的次数作为最终的变量重要性排名依据，出现次数越多表示变量的重要性更强。汇总结果如表 3-7 所示，由于一些变量总共出现的次数相同，因此具有相同的重要性排序。由于篇幅有限，正文仅展示出被筛选出的次数在 3 次及以上的变量。

表 3-13 重要性解释变量排序

变量名	重要性排序	变量名	重要性排序
FAQTOTAL	1	CATANIMSC	15
LDELTOTAL	1	ST97CV	15
GDTOTAL	2	TRABSCOR	15
ADAS_TOTAL	3	ST49TA	16
MMSCORE	4	ST146HS	17
LIMMTOTAL	5	ST24CV	17
ABETA	6	PTAU	17
ADNI_MEM	7	PHS	18
AVDELTOT	7	PTAU_RAW	18
PTEDUCAT	7	ST13TA	18
ST83TA	8	PTNOTRT	19
AVTOT6	9	RCT13	19
HCI	10	ST117TS	19
ST24TA	10	ST138HS	19
ADNI_EF	11	ST40TA	19
ST29SV	11	VSBPSYS	19
ABETA42	12	PXPERIPH	20
TAU	12	ST111CV	20
FATHDEM	13	ST119TS	20
ST110TS	13	ST144HS	20
ST136HS	13	ST18SV	20
ST137HS	14	ST32TA	20
ST77SV	14	ST60TA	20
ST88SV	14	ST93CV	20

按照变量类别进行划分，本文研究出的与阿尔兹海默症高度相关的变量有：

（1）认知和记忆能力：在筛选出的重要解释变量中，有 7 个都是与认知能力或者记忆能力相关的，且重要性排名都比较靠前。具体有逻辑即时记忆能力得分（LIMMTOTAL）、老年痴呆评估量表得分（ADAS_TOTAL）、逻辑延时回忆能力得分（LDELTOTAL）、Crane 实验室神经心理学记忆得分（ADNI_MEM）、简易智力状态

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

检查量表得分（MMSCORE）、Rey 听觉语言学习测试延时认知得分（AVDELTOT）、Rey 听觉语言学习测试六即时认知得分（AVTOT6）。记忆力和认知能力退化已经是被人们所熟知的阿尔兹海默症的最为显著特征，也因此是对患病最具识别能力的变量。而本文通过重要性排序可以发现，延时记忆能力的重要性高于即时记忆能力，随机森林计算出的重要性分数也可以验证出这一点。可以得出，延时记忆能力的退化更能预示着患阿尔兹海默症的风险，这是本文的一个新发现。

（2）生活能力：日常生活功能性评估得分（FAQTOTAL）、Crane 实验室神经心理学执行功能得分（ADNI_EF），是列举出了日常经常从事的某些活动，如购物、做饭、乘坐公共交通工具等，然后让受试者去衡量自己做这些活动的难易程度，以及是否需要他人帮助，最终获得一个评分。有些晚期痴呆的老年人由于认知能力下降，严重影响了日常活动，比如在出行后不记得回家的路，甚至每年有很多阿尔兹海默症患者外出后走失。对于难以独立完成日常活动的阿尔兹海默症患者，患者家属需要对他们多加看护，以保障他们的安全。

（3）心理学：老年抑郁量表总分（GDTOTAL）衡量了老年人的抑郁程度，并且从变量重要性排序上可以看出，这一变量对阿尔兹海默症的识别能力很强。在老年人患病后，因为记忆力退化以及生活不便，带来了对新事物的兴趣减退、精神空虚、感到无助和自我否定的情绪。这些抑郁倾向的情绪能够很好识别出阿尔兹海默症患者。同时，负面情绪的持续不利于患者的恢复，因此患者要培养良好的积极向上的心态，这有助于延缓病情的发展。阿尔兹海默症与抑郁情绪相关是本文的第二点新发现。

（4）生物标志物：以下脑部 MRI 图像观测到的形态异常与阿尔兹海默症高度相关。其中重要性排序最强的两个变量为右内嗅皮层皮质厚度平均值（ST83TA）、左内嗅皮层皮质厚度平均值（ST24TA）。内嗅皮层是大脑最重要的记忆中心之一，它的主要功能是在海马体之间传递信息。因此患阿尔兹海默症后，大脑中最先受到影响的区域之一就是内嗅皮层区域。由于海马体，而海马体是大脑的主要部分之一，也是长期记忆和空间导航的中心，因此海马体区域的部分变量也被筛选了出来，具体有左海马体积（WM 分割）（ST29SV）、海马亚区左下丘体积（ST137HS）、右海马体积（WM 分割）（ST88SV）、海马亚区左尾体积（ST138HS）、海马亚区右下丘体积（ST144HS）。颞部区域变量有颞上回左侧皮质厚度平均值（ST13TA）、右侧颞上皮质厚度标准差（ST117TS）、左颞中叶皮质平均厚度（ST40TA）、右颞极皮质厚度标准差（ST119TS）、左颞叶皮质平均厚度（ST32TA）、左颞极平均皮质厚度（ST60TA）。此外右小脑体积（WM 分割）（ST77SV）、左小脑体积（WM 分割）（ST18SV）右中央前皮质厚度标准差（ST110TS）、左内嗅皮层体积（皮质分割）（ST24CV）、右楔前叶体积（皮质分割）（ST111CV）、右侧扣带回体积(皮层分割)（ST93CV）与阿尔兹海默症病情也有很高的关联性。

以上为通过核磁共振成像得到的人脑区域的形态特征信息，通过 CSF 和 PET 测

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

出的 Aβ 蛋白（ABETA）、Tau 蛋白（TAU）、磷酸化 Tau 蛋白（PTAU）含量对于识别阿尔兹海默症也有很重要的作用。淀粉样 β 蛋白主要分布在皮层和海马区域，如果人脑不能正常代谢这些物质就会引起的脑中淀粉样蛋白的堆积，这将损害大脑神经，弱化大脑的学习和记忆功能。这是引起和加重阿尔兹海默病病情的重要原因之一[35]。

一些指标如血压收缩（毫米汞柱）（VSBPSYS）、外周血管是否正常（PXPERIPH）也预示着血管类疾病将增加罹患阿尔兹海默症的风险。此外，代谢趋缓指数（HCI）也是识别病情的重要变量。

（5）遗传学角度：父亲是否痴呆（FATHDEM）与阿尔兹海默症也具有很强的关联，因此家族有阿尔兹海默症病史的人群患病的风险更高。

（6）人口特征：受教育年限（PTEDUCAT）越高，患阿尔兹海默症的风险越低。退休（PTNOTRT）人群患阿尔兹海默症的风险高于未退休人群。由于劳动能够保持头脑的锻炼，延缓认知能力和记忆力退化，降低罹患痴呆的风险。因此我们应有意识的引导患病老年人多阅读书籍、培养爱好、多运动，增加锻炼脑力和体力的机会，防止认知能力进一步衰退。

综合上述重要解释变量的信息，可以得出阿尔兹海默症患者主要有记忆力和认知能力退化，独立生活能力较差，具有抑郁情绪，内嗅皮层、海马体、颞上回区域形态异常，Aβ 蛋白、Tau 蛋白、磷酸化 Tau 蛋白含量异常，有血管相关疾病，有家族痴呆病史，受教育年限低，没有从事劳动生活的特点。

[35] 李旭峰,丁小兵.基于 Aβ 沉积的阿尔兹海默病的治疗研究[J].世界最新医学信息文摘,2018,18(92):42-43.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

研究总结与展望

一、研究总结

本文介绍了阿尔兹海默症病情诊断的相关知识和背景。详细地阐述了用于进行阿尔兹海默症预测的模型原理。通过 ADNI 数据库中的数据，利用机器学习方法实现阿尔兹海默症的智能化诊断。本文的主要工作如下：

（1）首先对 ADNI 数据库下载得到的 700 余个数据文件及数据说明文件进行梳理，在 python 中整理得到包含了 ADNI1、ADNI-GO、ADNI2 的受试者基线诊断的生物标志物、评估得分、成像数据、人口统计学等数据。然后对数据进行描述性统计分析，通过绘制性别、教育年限等变量的百分比堆积条形图、箱线图，初步探索了一些变量与阿尔兹海默症的关系。

（2）由于原始数据中存在着异常信息，所以本文先对这些异常进行了剔除。为保证插补效果，下一步对清洗后的数据剔除了缺失比例在 45%以上的变量，并对剩下的分类变量进行了哑变量处理，对连续性变量进行了归一化。最终得到的数据包含了 1730 个样本和 533 个变量。最后整理出了数据集的缺失情况。

（3）在利用训练集进行建模前，首先确定合适的代价权重比值，以降低预测时将患者诊断为正常人的误判率。然后对数据进行插补，通过随机森林插补法和正则化迭代 PCA 插补法得到完整的数据集。建模总共分三个部分。第一部分，对两种插补法得到的数据集分别建立 Logistic 回归模型，再利用向前选择法，找出对阿尔兹海默症诊断解释力最强的变量。第二部分分别利用完整的数据集建立插补法 SVM 模型。第三部分，同样利用插补好的两个完整数据集建立插补法随机森林模型，并计算出变量重要性分数。第四部分，利用 SAEM 法直接对缺失数据进行建模，选择使模型收敛速度最快的参数，一次性完成数据的插补和 Logistic 回归模型的建立。

（4）对测试集进行预测，对比不同模型的预测效果，并给出对于阿尔兹海默症病情诊断解释性强的变量。为减小偶然性带来的建模结果影响，本文将对（3）和（4）中的过程重复进行 10 次，用 10 次建模得到的准确率、精确率、灵敏度、特异度、AUC 等指标的平均值进行模型间的比较。结果显示，预测能力最好的模型为 SAEM 模型，其平均 AUC 值能够达到 98.05%，准确率可以达到 91.62%，召回率高达 98.78%，能够对阿尔兹海默症患者做出良好的预测。

二、研究展望

由于研究时间以及作者能力有限，本论文的研究内容还存在一些不足之处，因而

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

关于本文的研究内容还可以从以下方面来进行优化，例如：

（1）本论文仅仅是对这 7 种使用到的机器学习算法的直接应用，而没有对算法本身进行创新和进一步的优化，这是后续研究需要做出的一个改进方面。

（2）本文为了降低将患者诊断为正常人的误判率，提出了加权误判率的概念。在得到预测概率后选择能使加权误判率最小的阈值进行预测分类。虽然这一操作能够提升模型的灵敏度，但是也使得特异度有所下降。在未来的研究中，将进一步寻找能够提升模型灵敏度，同时能够不牺牲太多特异度的方法。

（3）在筛选出重要变量后，由于医学专业知识欠缺，因此只给出了与阿尔兹海默症病情相关联的脑部区域形态特征以及其他生物标志物，对于两者之间是如何关联，缺乏专业性的解释。

（4）Wei Jiang、Julie Josse 等人在提出 SAEM 算法时也提供了相应的变量选择方法。但是该方法的运行消耗大量内存，且运算时间过长，无法在日常使用的电脑上运行。由于硬件受限，所以本文在实证部分没有进行这一部分的探索，在后续研究中可以进行利用算力更强大的设备来进一步研究。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

参考文献

[1] 陈庆华,张凤强,李立新,等.阿尔茨海默病发病机制和诊断技术研究进展[J].中华老年心脑血管病杂志,2018,20(01):108-110.

[2] 陈婉娇.缺失数据插补方法及其在医学领域的应用研究[D].广东:华南理工大学,2019.

[3] 陈雅琳.基于深度学习的癌症基因数据分类研究与实现[D].四川:电子科技大学,2019.

[4] 方匡南,吴见彬,朱建平,等.随机森林方法研究综述[J].统计与信息坛,2011,26(3):32-38.

[5] 郭志旺.随机森林和支持向量机在乳腺癌高维转录组数据中的应用[D].河北:河北医科大学,2019.

[6] 贾建平,李妍.中国痴呆的现状和未来[J].中华神经科杂志,2020(02):81-84.

[7] 雷炳业,潘嘉瑜,吴逢春,等.基于机器学习的神经精神疾病辅助诊断研究进展[J].中国医学物理学杂志,2020,37(02):257-264.

[8] 李长胜,王瑜,肖洪兵,等.KPCA 和 Adaboost 算法在阿尔茨海默症功能磁共振影像分类中的应用[J].中国医学物理学杂志,2019,36(07):784-788.

[9] 李航.统计学习方法[M].北京:清华大学出版社.2012:117-183.

[10] 李琳,杨红梅,杨日东,等.基于临床数据集的缺失值处理方法比较[J].中国数字医学,2018,13(04):8-10+80.

[11] 李璐.基于 R 语言的缺失值填补方法[J].统计与决策,2012(17):72-74.

[12] 李旭峰,丁小兵.基于 Aβ 沉积的阿尔兹海默病的治疗研究[J].世界最新医学信息文摘,2018,18(92):42-43.

[13] 梁丽军,刘子先,王化强.基于弹性网-SVM 的疾病诊断关键特征识别[J].计算机应用研究,2015,32(05):1301-1304+1308.

[14] 梁丽明,陈文智,于德娥,等.吸烟与阿兹海默症关联性的 meta 分析[J].职业与健康,2021,37(01):103-106.

[15] 梁霞.缺失数据的多重插补及其改进[D].中南大学,2007.

[16] 林颖.深度学习及在医学图像分析中的应用[D].南华大学,2019.

[17] 林颖,何啸峰,陈灵娜,等.结合 DCGAN 与 LSTM 的阿兹海默症分类算法[J].计算机应用研究,2020,37(5):1574-1577.

[18] 刘伶俐,王端.人工智能在医疗领域的应用与存在的问题[J].卫生软科学,2020,34(10):23-27.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

[19]刘铭,聂磊,周芷茜.T-S 模糊神经网络在冠心病智能诊断中的应用[J].科技导报,2018,36(17):91-96.
[20]刘文广,谢斯敏,周雅芳,等.机器学习及其在肝脏疾病影像诊断中的研究进展[J].国际医学放射学杂志,2019,42(01):16-21.
[21]刘晓秋,白志军.中国老年人群阿尔茨海默病相关危险因素分析[J].医学与哲学(B),2015,36(07):43-46.
[22]吕鸿蒙,赵地,迟学斌.基于增强 AlexNet 的深度学习的阿尔茨海默病的早期诊断[J].计算机科学,2017,44(S1):50-60.
[23]潘传快,祁春节,李思璇.正态线形模型下缺失值的 Bootstrap 多重插补与比较[J].统计与决策,2017(10):14-17.
[24]潘祖江,刘宁,张伟,等.基于层次注意力机制的多任务疾病进展模型[J].计算机科学,2020,47(09):185-189.
[25]庞新生.缺失数据处理方法的比较[J].统计与决策,2010(24):152-155.
[26]庞新生.缺失数据多重插补处理方法的算法实现[J].统计与决策,2012(11):88-90.
[27]沈琳,胡国清,陈立章,等.缺失森林算法在缺失值填补中的应用[J].中国卫生统计,2014,31(05):774-776.
[28]师浩斌.基于卷积神经网络的帕金森病语音障碍诊断研究[D].河北:燕山大学,2017.
[29]宋亮,万建洲.缺失数据插补方法的比较研究[J].统计与决策,2020,36(18):10-14.
[30]宋祯彦,余婧萍,贺春香,等.不同阶段阿尔茨海默病患者海马 CA1 区基因表达的生物信息学分析[J].世界科学技术-中医药现代化,2019,21(09):1791-1798.
[31]苏玮琦.机器学习分类算法在肝病诊断中的应用[D].华中师范大学,2020.
[32]唐牟尼,刘协和,云扬,等.社区阿尔茨海默病危险因素病例对照研究[J].中国心理卫生杂志,2001(01):22-25.
[33]仝政霖.基于深度学习的阿兹海默症基因表达模式识别与样本分类[D].东南大学,2018.
[34]王晓妮,唐毅,韩璎.阿尔茨海默病诊断标准的演变[J].医学研究生学报,2015,28(02):195-198.
[35]王弈,李传富.人工智能方法在医学图像处理中的研究新进展[J].中国医学物理学杂志,2013,30(03):4138-4143.
[36]王奕,夏树涛.集成学习之随机森林算法综述[J].信息通信技术,2018,12(01):49-55.
[37]王英全,梁景宏,贾瑞霞,等.2020-2050 年中国阿尔茨海默病患病情况预测研究[J].阿尔茨海默病及相关病,2019,2(01):289-298.
[38]熊巍,潘传快,祁春节.农业经济调查缺失数据的贝叶斯和 Bootstrap 多重插补的比较[J].统计与决策,2019,35(04):11-15.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

[39]杨宝琴,干雪琴,张建英,等.老年阿尔茨海默病患者生活方式中危险因素的病例对照研究[J].解放军护理杂志,2014,31(10):41-43.

[40]杨日东,李琳,陈秋源,周毅.LKNNI:一种局部 K 近邻插补算法[J].中国卫生统计,2019,36(05):780-783.

[41]张彪,韩伟,庞海玉,等.完全随机缺失条件下分类随机变量数据缺失插补方法的比较研究[J].中国卫生统计,2015,32(4):903-905.

[42]张曦濛,蔡晓莹,方燕南.认知障碍患者血浆集落刺激因子、炎性因子分析[J].临床荟萃,2017,32(09):774-777.

[43]张应腾.支持向量机在阿尔茨海默症演变过程中的多模态和纵向分类研究[D].广东:华南理工大学,2019.

[44]张子俊.机器学习在角膜相关疾病辅助诊断中的应用[J].中华实验眼科杂志,2020,38(09):804-808.

[45]赵可扬,杨沐月,朱静妤,等.机器学习辅助肿瘤诊断[J].肿瘤,2018,38 (10):987-991.

[46]钟志良,黄嘉艺,林绍嘉.MRI 对血管性痴呆与阿尔兹海默症的诊断鉴别作用[J].世界复合医学,2020,6(06):140-142.

[47]周文,王瑜,李长胜,等.LightGBM 算法在阿尔茨海默症结构磁共振成像分类中的应用[J].中国医学物理学杂志,2019,36(04):408-413.

[48]周文,王瑜,肖红兵,等.基于 KPCA 算法的阿尔茨海默症辅助诊断[J].中国医学物理学杂志,2018,35(04):404-409.

[49]周志华.机器学习[M].北京:清华大学出版社,2016:121-140.

[50]宗慧,赵韡.应用机器学习算法构建心梗患者风险预测模型[J].中国数字医学,2016,11(04):104-106.

[51]Alexander Lebedev, Eric Westman, Gerard Westen, et al. Random Forest ensembles for detection and prediction of Alzheimer's disease with a good between cohort robustness[J]. NeuroImage: Clinical, 2014, 6: 115-125.

[52]Angela Wood, Ian White, Patrick Royston. How should variable selection be performed with multiply imputed data?[J].Statistics in Medicine, 2008, 27(17): 3227-3246.

[53]Audigier Vincent, Husson Francois, Josse Julie. A principal component method to impute missing values for mixed data[J]. Advances in data analysis and classification, 2016, 10(1): 5-26.

[54]Balsis Steve, Benge Jared, Lowe Deborah, et al. How do scores on the ADAS-Cog, MMSE, and CDR-SOB correspond?[J]. The Clinical neuropsychologist, 2015, 29(7): 1002-1009.

[55]Beltrán Juan Felipe, Wahba Brandon Malik, Nicole Hose, et al. Inexpensive, non-invasive biomarkers predict Alzheimer transition using machine learning analysis of the

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

Alzheimer's Disease Neuroimaging (ADNI) database[J]. PlOS ONE,2020, 15(7): e0234663.

[56] Bin Tufail Ahsan, Abidi Ali, Siddiqui Adil Masood, et al. Multiclass classification of initial stages of Alzheimer's disease using structural MRI phase images[C].//2012 IEEE international conference on control system, computing and engineering: ICCSCE 2012, Penang, Malaysia, 23-25 November 2012.2012:317-321.

[57] Christos Davatzikos, Priyanka Bhatt, Leslie Shaw, et al. Prediction of MCI to AD conversion, via MRI, CSF biomarkers, and pattern classification[J]. Neurobiol Aging, 2010, 32(12): e19-e27.

[58] Daniela Bertens, Dirk Knol, Philip Scheltens, et al. Temporal evolution of biomarkers and cognitive markers in the asymptomatic, MCI, and dementia stage of Alzheimer's disease[J]. Alzheimer's & Dementia, 2014, 11(5): 46-52.

[59] Fjell Anders, Walhovd Kristine, Fennema-Notestine Christine, et al. CSF biomarkers in prediction of cerebral and clinical change in mild cognitive impairment and Alzheimer’s disease[J]. Journal of Neuroscience, 2010, 30(6): 2088-2101.

[60] Jack de la Torre. Vascular risk factor detection and control may prevent Alzheimer's disease[J]. Ageing Research Reviews, 2010, 9(4): 218-225.

[61] Joseph Schafer, Nathaniel Schenker. Inference with imputed conditional means[J]. Journal of the American Statistical Association, 2000, 95(499): 144-154.

[62] Julie Josse, François Husson. missMDA: A Package for Handling Missing Values in Multivariate Data Analysis[J]. Journal of Statistical Software, 2016, 70(4): 61-97.

[63] Julie Josse, Marie Chavent, Benot Liquet, et al. Handling missing values with regularized iterative multiple correspondence analysis[J]. Journal of classification, 2012, 29(1): 91-116.

[64] Ronald Petersen. Mild cognitive impairment clinical trials[J]. Nature Reviews Drug Discovery,2003,2(8):646-653.

[65] Silvia Basaia, Federica Agosta, Luca Wagner, et al. Automated classification of Alzheimer's disease and mild cognitive impairment using a single MRI and deep neural networks[J]. NeuroImage: Clinical, 2019, 21(12): 101645.

[66] Shaw Leslie, Vanderstichele Hugo, Malgorzata Clark, et al. Cerebrospinal fluid biomarker signature in Alzheimer’s disease neuroimaging initiative subjects[J]. Ann Neurol, 2009, 65(4): 403-413.

[67] Shi Bibo, Chen Yani, Zhang Pin, et al. Nonlinear feature transformation and deep fusion for Alzheimer's Disease staging analysis[J]. Pattern Recognition: The Journal of the Pattern Recogni-tion Society, 2017, 63: 487-498.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

[68] Stekhoven Daniel, Bühlmann Peter. MissForest-non-parametric missing value imputation for mixed-type data[J]. Bioinformatics, 2012, 28(1): 8-112.

[69] Tufail Ahsan, Abidi Ali, Siddiqui Adil, et al. Automatic classification of initial categories of Alzheimer's disease from structural MRI phase images: A comparison of PSVM, KNN and ANN methods[J]. Age, 2012, 75: 13-76.

[70] Vincent Audigier, François Husson, Julie Josse. Multiple imputation for continuous variables using a Bayesian principal component analysis[J]. Journal of Statistical Computation and Simulation, 2016, 86(11): 54-73.

[71] Wei Jiang, Julie Josse, Marc Lavielle. Logistic regression with missing covariates-Parameter estimation, model selection and prediction within a joint-modeling framework[J]. Computational Statistics and Data Analysis, 2020, 145: 106907.

[72] Ye Jieping, Farnum Michael, Yang Eric, et al. Sparse learning and stability selection for predicting MCI to AD conversion using baseline ADNI data[J]. BMC Neurology, 2012, 12(1): 46.

[73] Yueqin Huang, Yu Wang, Hong Wang, et al. Prevalence of mental disorders in China: a cross-sectional epidemiological study[J]. The Lancet Psychiatry, 2019, 6(3): 12-16.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

附录

表 1 解释变量说明

变量名	变量含义
FAQTOTAL	日常生活功能性评估得分
LDELTOTAL	逻辑延时回忆能力得分
GDTOTAL	老年抑郁量表总分，衡量了老年人的抑郁程度
ADAS_TOTAL	老年痴呆评估量表得分
MMSCORE	简易智力状态检查量表得分
LIMMTOTAL	逻辑即时记忆能力得分
ABETA	Aβ 蛋白
ADNI_MEM	Crane 实验室神经心理学记忆得分
AVDELTOT	Rey 听觉语言学习测试延时认知得分
PTEDUCAT	受教育年限
ST83TA	右内嗅皮层皮质厚度平均值
AVTOT6	Rey 听觉语言学习测试六即时认知得分
HCI	代谢趋缓指数
ST24TA	左内嗅皮层皮质厚度平均值
ADNI_EF	Crane 实验室神经心理学执行功能得分
ST29SV	左海马体积（WM 分割）
ABETA42	Aβ42 蛋白
TAU	Tau 蛋白
FATHDEM	父亲是否痴呆
ST110TS	右中央前皮质厚度标准差
ST136HS	左下缘前海马亚野体积
ST137HS	海马亚区左下丘体积
ST77SV	右小脑体积（WM 分割）
ST88SV	右海马体积（WM 分割）
CATANIMSC	动物类别识别正确数
ST97CV	右舌体积（皮质分异）
TRABSCOR	精神测试 B 部分完成时间
ST49TA	左侧中央后皮层平均厚度
ST146HS	海马亚野右尾体积

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

续表

变量名	变量含义
ST24CV	左内嗅皮层体积（皮质分割）
PTAU	磷酸化 Tau 蛋白
ST13TA	颞上回左侧皮质厚度平均值
PTNOTRT	是否退休
ST117TS	右侧颞上皮质厚度标准差
ST138HS	海马亚区左尾体积
ST40TA	左颞中叶皮质平均厚度
VSBPSYS	血压收缩（毫米汞柱）
PXPERIPH	外周血管是否正常
ST111CV	右楔前叶体积（皮质分割）
ST119TS	右颞极皮质厚度标准差
ST144HS	海马亚区右下丘体积左小脑体积（WM 分割）
ST18SV	左小脑 WM 体积（WM 分割）
ST32TA	左颞叶皮质平均厚度
ST60TA	左颞极平均皮质厚度
ST93CV	右侧扣带回体积（皮层分割）

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net